NOTAS DE REVISÃO EM ABERTO

- ☐ **EMS:** O resumo ainda não apresenta a lacuna nem a contribuição pretendida. Também falta mencionar o resultado preliminar da análise exploratória. Revisar depois de fechar os objetivos. . . . 2
- ☐ **EMS:** Evite afirmações quantitativas sem fonte (“milhões”, “prejuízos enormes”). Ou se cita um dado verificável, ou se descreve o fenômeno sem quantificar. . . . 10
- ☐ **EMS:** Frase opinativa, sem sustentação na literatura. Removida. . . . 10
- ☐ **EMS:** A lacuna está correta na direção, mas ainda ampla. “Poucos trabalhos aplicados a São Paulo” não basta como lacuna científica: é preciso dizer o que a literatura não resolve. Sugestão para a qualificação: investigar se a literatura trata a *explicação* das previsões para o gestor. Isso conversa com a linha de Sistemas Inteligentes e delimita melhor a contribuição. . . . 10
- ☐ **EMS:** A pergunta “como pode” não é verificável. Reformular em termos mensuráveis: em que medida, com qual horizonte, avaliado por quais métricas. . . . 10
- ☐ **Pendente:** Definir o quarto objetivo: avaliar a apresentação das previsões ao gestor (painel). . . . 11
- ☐ **EMS:** O objetivo geral precisa de verbo avaliável e de delimitação: horizonte de previsão, variável prevista e finalidade (apoio à decisão). “Propor” sozinho não permite verificar se foi atingido. . . . 11
- ☐ **Pendente:** Incluir os modelos de *boosting* (Friedman, 2001; Chen e Guestrin, 2016), que a literatura indica como mais precisos em dados tabulares. . . . 12
- ☐ **EMS:** Esta seção deve ganhar uma subseção sobre explicabilidade (XAI), caso a lacuna seja redefinida como sugerido no Capítulo 1. Começar por Arrieta *et al.* (2020) e Lundberg; Lee (2017). . . . 12
- ☐ **EMS:** O quadro ainda é descritivo. Na qualificação, os estudos devem vir da revisão sistemática, e o texto após o quadro precisa argumentar por que eles não resolvem a lacuna. . . . 13
- ☐ **EMS:** Falta justificar cada enquadramento com literatura metodológica. Considerar a *Design Science Research* (Hevner *et al.*, 2004), já que o produto final é um artefato. 14
- ☐ **Pendente:** Confirmar com a instituição parceira o período disponível e as condições de uso dos dados. . . . 15
- ☐ **EMS:** Duas observações. (1) Use `\eqref` para citar equações, e não `\ref`: os parênteses fazem parte da numeração. (2) Defina o protocolo de validação: com séries temporais, a validação cruzada comum embaralha passado e futuro. Ver Bergmeir; Benítez (2012). . . . 15
- ☐ **EMS:** Bom ponto de partida. Para a qualificação, incluir uma prova de conceito com ao menos um modelo de referência (média histórica) e um modelo de aprendizado de máquina. . . . 17

☐ **EMS:** O cronograma usa trimestres, mas há colunas vazias no fim da tabela. Ajustar a estrutura e detalhar mais as atividades após a qualificação. 18

☐ **EMS:** Incluir termos de explicabilidade na versão definitiva da busca, se a lacuna for redefinida. 22

Legenda de revisores

- **EMS**: Prof. Dr. Edson Melo de Souza (orientador)
- **Coor**: Coorientador(a)
- **Aluno**: Autor(a) do trabalho
- **Banca**: Membro da banca examinadora

UNIVERSIDADE NOVE DE JULHO – UNINOVE
PROGRAMA DE PÓS-GRADUAÇÃO EM INFORMÁTICA E GESTÃO DO CONHECIMENTO – PPGI

MARINA EXEMPLO DE OLIVEIRA

SISTEMAS INTELIGENTES PARA RESOLUÇÃO DE PROBLEMAS DE TRÂNSITO EM SÃO PAULO

São Paulo
2025

MARINA EXEMPLO DE OLIVEIRA

SISTEMAS INTELIGENTES PARA RESOLUÇÃO DE PROBLEMAS DE TRÂNSITO EM SÃO PAULO

Texto de Pré-Qualificação de Mestrado, elaborado na disciplina de Seminários em Tecnologia da Informação Inteligente, apresentado ao Programa de Pós-Graduação em Informática e Gestão do Conhecimento (PPGI) da Universidade Nove de Julho (UNINOVE), como requisito parcial para a obtenção do grau de Mestra em Informática e Gestão do Conhecimento.

Orientador: Prof. Dr. Edson Melo de Souza

Data de ingresso: 03/2025
Linha de pesquisa: LP2 – Sistemas Inteligentes

São Paulo
2025

RESUMO

Os congestionamentos estão entre os principais problemas urbanos da cidade de São Paulo, com impactos sobre o tempo de deslocamento, a economia e o meio ambiente. Os sistemas inteligentes de transporte, apoiados em técnicas de aprendizado de máquina, oferecem meios para antecipar essas situações e apoiar a gestão do tráfego. Este projeto de pesquisa tem como objetivo propor um sistema inteligente para a previsão de congestionamentos na cidade de São Paulo. Pretende-se realizar uma revisão sistemática da literatura, construir uma base de dados de lentidão viária e condições meteorológicas e comparar modelos estatísticos e de aprendizado de máquina.

EMS: O resumo ainda não apresenta a lacuna nem a contribuição pretendida. Também falta mencionar o resultado preliminar da análise exploratória. Revisar depois de fechar os objetivos.

A análise exploratória preliminar, realizada com dados de 2023, confirma a existência de padrões horários e semanais bem definidos, o que indica a viabilidade da abordagem proposta.

Palavras-chave: sistemas inteligentes; trânsito; previsão de tráfego; aprendizado de máquina.

ABSTRACT

Traffic congestion is among the main urban problems in the city of São Paulo, with impacts on travel time, the economy and the environment. Intelligent transportation systems, supported by machine learning techniques, provide means to anticipate these situations and support traffic management. This research project aims to propose an intelligent system for forecasting congestion in the city of São Paulo. A systematic literature review will be carried out, a dataset of traffic congestion and weather conditions will be built, and statistical and machine learning models will be compared. The preliminary exploratory analysis, carried out with 2023 data, confirms the existence of well-defined hourly and weekly patterns, which indicates the feasibility of the proposed approach.

Keywords: intelligent systems; traffic; traffic forecasting; machine learning.

LISTA DE FIGURAS

Figura 1 – Desenho preliminar da pesquisa 14

Figura 2 – Perfil horário médio da extensão de lentidão por tipo de dia, 2023 17

LISTA DE QUADROS

Quadro 1 – Trabalhos relacionados identificados na busca exploratória 13

Quadro 2 – Protocolo preliminar da revisão sistemática 15

Quadro 3 – Cronograma preliminar de atividades 18

Quadro 4 – Expressão de busca preliminar para a base Scopus 22

LISTA DE TABELAS

Tabela 1 – Estatísticas descritivas da extensão de lentidão (km), 2023 17

LISTA DE ABREVIATURAS E SIGLAS

IA	Inteligência Artificial
ITS	*Intelligent Transportation Systems* (Sistemas Inteligentes de Transporte)
MAE	*Mean Absolute Error* (erro absoluto médio)
PRISMA	*Preferred Reporting Items for Systematic Reviews and Meta-Analyses*
RF	*Random Forest* (floresta aleatória)
RMSE	*Root Mean Squared Error* (raiz do erro quadrático médio)
SARIMA	*Seasonal AutoRegressive Integrated Moving Average*

LISTA DE SÍMBOLOS

p, d, q	Ordens não sazonais do modelo SARIMA
P, D, Q	Ordens sazonais do modelo SARIMA
s	Período sazonal
ϕ_p, Φ_P	Polinômios autorregressivos não sazonal e sazonal
B	Operador de defasagem, $By_t = y_{t-1}$
y_t	Extensão de lentidão observada na hora t (km)
θ_q, Θ_Q	Polinômios de médias móveis não sazonal e sazonal
ε_t	Termo de erro aleatório
t	Índice temporal (hora)
$\mathbf{x}$	Vetor de variáveis preditoras
T	Número de árvores da floresta aleatória
h_b	Árvore de decisão b
$\hat{y}_t$	Extensão de lentidão prevista para a hora t (km)
n	Número de observações do conjunto avaliado

SUMÁRIO

1 INTRODUÇÃO 10

1.1 Contextualização 10

1.2 Problema de pesquisa 10

1.3 Objetivos 11

1.3.1 Objetivo geral 11

1.3.2 Objetivos específicos 11

1.4 Justificativa 11

1.5 Organização do trabalho 11

2 FUNDAMENTAÇÃO TEÓRICA 12

2.1 Sistemas inteligentes de transporte 12

2.2 Previsão de tráfego de curto prazo 12

2.3 Aprendizado de máquina baseado em árvores 12

2.4 Trabalhos relacionados 13

3 METODOLOGIA 14

3.1 Classificação da pesquisa 14

3.2 Desenho da pesquisa 14

3.3 Procedimentos de levantamento da literatura 14

3.4 Procedimentos de coleta de dados 15

3.5 Procedimentos de análise de dados 15

3.6 Aspectos éticos 15

3.7 Delimitações e limitações do estudo 16

4 RESULTADOS PRELIMINARES 17

4.1 Análise exploratória preliminar 17

5 PLANOS PARA A CONTINUIDADE DO TRABALHO 18

5.1 Atividades previstas até a qualificação 18

5.2 Atividades previstas da qualificação à defesa 18

5.3 Cronograma 18

DECLARAÇÃO DE USO DE IA GENERATIVA 19

REFERÊNCIAS 20

APÊNDICE A – Expressão de busca preliminar 22

1 INTRODUÇÃO

1.1 Contextualização

O trânsito é um dos maiores problemas da cidade de São Paulo. ~~Todos os dias, milhões de pessoas perdem horas presas em congestionamentos, o que causa prejuízos enormes para a economia e para a saúde da população.~~ O crescimento da frota de veículos e a concentração de atividades em poucas regiões produzem congestionamentos recorrentes, com impactos sobre o tempo de deslocamento, a economia e a qualidade do ar.

EMS: Evite afirmações quantitativas sem fonte (“milhões”, “prejuízos enormes”). Ou se cita um dado verificável, ou se descreve o fenômeno sem quantificar.

Com o avanço da tecnologia, surgiram os Sistemas Inteligentes de Transporte (*Intelligent Transportation Systems*, ITS), que utilizam dados de sensores e dispositivos para melhorar a operação do tráfego (Zhang *et al.*, 2011). Entre as funções desses sistemas, a previsão de curto prazo das condições de tráfego ocupa posição central, pois permite antecipar congestionamentos e acionar medidas preventivas (Vlahogianni; Karlaftis; Golias, 2014).

A Inteligência Artificial (IA), e em especial o aprendizado de máquina, permite construir modelos capazes de aprender padrões a partir de dados históricos e prever situações futuras. ~~A IA é a tecnologia mais importante do século e vai resolver os problemas de trânsito das grandes cidades.~~

EMS: Frase opinativa, sem sustentação na literatura. Removida.

Este trabalho propõe a aplicação dessas técnicas ao problema dos congestionamentos em São Paulo.

1.2 Problema de pesquisa

Apesar da existência de diversos estudos sobre previsão de tráfego, ainda há poucos trabalhos aplicados à realidade de São Paulo, que considerem fatores locais como as chuvas de verão e o calendário de feriados.

EMS: A lacuna está correta na direção, mas ainda ampla. “Poucos trabalhos aplicados a São Paulo” não basta como lacuna científica: é preciso dizer o que a literatura não resolve. Sugestão para a qualificação: investigar se a literatura trata a *explicação* das previsões para o gestor. Isso conversa com a linha de Sistemas Inteligentes e delimita melhor a contribuição.

Lacuna de Pesquisa. Há poucos estudos sobre previsão de congestionamentos com aprendizado de máquina aplicados ao contexto da cidade de São Paulo.

Pergunta de Pesquisa. Como um sistema inteligente baseado em aprendizado de máquina pode prever congestionamentos na cidade de São Paulo?

EMS: A pergunta “como pode” não é verificável. Reformular em termos mensuráveis: em que medida, com qual horizonte, avaliado por quais métricas.

1.3 Objetivos

1.3.1 Objetivo geral

Propor um sistema inteligente para a previsão de congestionamentos na cidade de São Paulo.

1.3.2 Objetivos específicos

1. Realizar uma revisão sistemática da literatura sobre previsão de tráfego.
2. Construir uma base de dados de lentidão viária e condições meteorológicas.
3. Comparar modelos estatísticos e de aprendizado de máquina.
4.

Pendente: Definir o quarto objetivo: avaliar a apresentação das previsões ao gestor (painel).

EMS: O objetivo geral precisa de verbo avaliável e de delimitação: horizonte de previsão, variável prevista e finalidade (apoio à decisão). “Propor” sozinho não permite verificar se foi atingido.

1.4 Justificativa

A previsão antecipada de congestionamentos pode ajudar os órgãos de trânsito a tomar decisões preventivas, como ajustar semáforos e posicionar equipes de campo. Do ponto de vista acadêmico, o trabalho contribui para a aplicação de técnicas de aprendizado de máquina a um problema real de grande relevância social.

1.5 Organização do trabalho

Além desta Introdução, o trabalho está estruturado em quatro capítulos:

- Capítulo 2 (**Fundamentação teórica**). Apresenta os conceitos de sistemas inteligentes de transporte e os principais métodos de previsão de tráfego.
- Capítulo 3 (**Metodologia**). Descreve os procedimentos previstos para a pesquisa.
- Capítulo 4 (**Resultados preliminares**). Apresenta a análise exploratória inicial dos dados.
- Capítulo 5 (**Planos para a continuidade do trabalho**). Detalha as atividades previstas até a qualificação e a defesa.

2 FUNDAMENTAÇÃO TEÓRICA

Resumo do capítulo

Este capítulo apresenta os conceitos iniciais que fundamentam o projeto: os sistemas inteligentes de transporte, a previsão de tráfego de curto prazo, com destaque para os modelos sazonais, e os modelos de aprendizado de máquina baseados em árvores de decisão. Por fim, são apresentados os primeiros trabalhos relacionados identificados.

2.1 Sistemas inteligentes de transporte

Um sistema inteligente pode ser compreendido como um agente que percebe seu ambiente e age de modo a maximizar o alcance de seus objetivos (Russell; Norvig, 2021). Nos transportes, os ITS aplicam essa ideia à rede viária, coletando dados sobre o tráfego e apoiando ações de controle e informação. Zhang *et al.* (2011) descrevem a transição para os ITS orientados por dados, nos quais os modelos passam a ser aprendidos a partir de grandes volumes de registros.

2.2 Previsão de tráfego de curto prazo

A previsão de curto prazo estima as condições da via em horizontes de minutos a poucas horas (Vlahogianni; Karlaftis; Golias, 2014). Entre os modelos estatísticos, destacam-se os modelos SARIMA, cuja estrutura sazonal se ajusta à periodicidade diária e semanal do tráfego (Williams; Hoel, 2003). Um modelo SARIMA$(p,d,q)(P,D,Q)_s$ é expresso pela Equação (2.1) (Hyndman; Athanasopoulos, 2021):

$$\phi_p(B)\,\Phi_P(B^s)\,(1-B)^d\,(1-B^s)^D\,y_t = \theta_q(B)\,\Theta_Q(B^s)\,\varepsilon_t, \tag{2.1}$$

em que y_t é o valor da série no instante t, B é o operador de defasagem, s é o período sazonal, ϕ_p, Φ_P, θ_q e Θ_Q são os polinômios autorregressivos e de médias móveis, e ε_t é o termo de erro.

2.3 Aprendizado de máquina baseado em árvores

As florestas aleatórias (*Random Forest*, RF) combinam várias árvores de decisão treinadas sobre amostras diferentes dos dados (Breiman, 2001). A previsão final corresponde à média das previsões das árvores, conforme a Equação (2.2):

$$\hat{f}_{\mathrm{RF}}(\mathbf{x}) = \frac{1}{T}\sum_{b=1}^{T} h_b(\mathbf{x}), \tag{2.2}$$

em que $\mathbf{x}$ é o vetor de variáveis preditoras, T é o número de árvores e h_b é a b-ésima árvore.

Pendente: Incluir os modelos de *boosting* (Friedman, 2001; Chen e Guestrin, 2016), que a literatura indica como mais precisos em dados tabulares.

EMS: Esta seção deve ganhar uma subseção sobre explicabilidade (XAI), caso a lacuna seja redefinida como sugerido no Capítulo 1. Começar por Arrieta *et al.* (2020) e Lundberg; Lee (2017).

2.4 Trabalhos relacionados

O Quadro 1 apresenta os primeiros trabalhos identificados na busca exploratória, que antecede a revisão sistemática prevista na Seção 3.3.

Quadro 1 – Trabalhos relacionados identificados na busca exploratória

ID	Referência	Foco metodológico	Principal contribuição
E01	Williams; Hoel (2003)	Modelagem SARIMA do fluxo veicular.	Fundamentação da sazonalidade do tráfego em séries temporais.
E02	Vlahogianni; Karlaftis; Golias (2014)	Revisão sobre previsão de curto prazo.	Agenda de pesquisa para o campo.
E03	Lv *et al.* (2015)	Aprendizado profundo.	Ganho de acurácia em grandes volumes de dados.

Fonte: Elaborado pela autora (2025).

EMS: O quadro ainda é descritivo. Na qualificação, os estudos devem vir da revisão sistemática, e o texto após o quadro precisa argumentar por que eles não resolvem a lacuna.

3 METODOLOGIA

Resumo do capítulo

Este capítulo descreve os procedimentos previstos para a pesquisa. A investigação será aplicada, de abordagem quantitativa, e organizada em três etapas: revisão sistemática da literatura, construção da base de dados e modelagem preditiva. São apresentados o protocolo preliminar da revisão, as fontes de dados previstas e as métricas de avaliação dos modelos.

3.1 Classificação da pesquisa

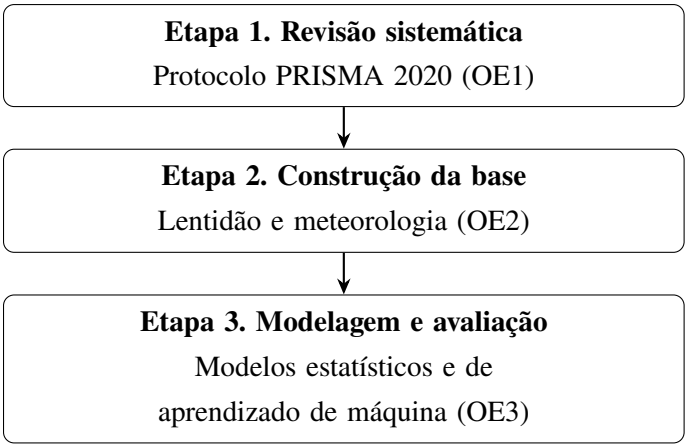
Quanto à natureza, a pesquisa será aplicada, pois busca solucionar um problema concreto da gestão do tráfego. Quanto à abordagem, será quantitativa, e quanto aos procedimentos, combinará pesquisa bibliográfica e experimentação computacional.

EMS: Falta justificar cada enquadramento com literatura metodológica. Considerar a *Design Science Research* (Hevner *et al.*, 2004), já que o produto final é um artefato.

3.2 Desenho da pesquisa

A Figura 1 apresenta as etapas previstas e sua correspondência com os objetivos específicos (OE).

Figura 1 – Desenho preliminar da pesquisa



Fonte: Elaborada pela autora (2025).

3.3 Procedimentos de levantamento da literatura

A revisão sistemática seguirá as diretrizes de Kitchenham; Charters (2007) e será relatada conforme a recomendação PRISMA 2020 (Page *et al.*, 2021). O Quadro 2 resume o protocolo preliminar, e a expressão de busca inicial encontra-se no Apêndice A.

Quadro 2 – Protocolo preliminar da revisão sistemática

Elemento	**Definição**
Bases de dados	Scopus e Web of Science
Período	2015 a 2025
Idioma e tipo	Artigos em inglês
Inclusão	Estudos com avaliação empírica de previsão de curto prazo
Exclusão	Previsão de longo prazo; estudos sem métricas de erro

Fonte: Elaborado pela autora (2025).

3.4 Procedimentos de coleta de dados

Prevê-se a construção de uma base horária com a extensão total de lentidão monitorada na cidade, em quilômetros, e com variáveis meteorológicas e de calendário. Para a análise exploratória preliminar, foram utilizados os dados de 2023[1]. A base completa deverá abranger o período de 2022 a 2024[?], condicionada à autorização de acesso.

Pendente: Confirmar com a instituição parceira o período disponível e as condições de uso dos dados.

3.5 Procedimentos de análise de dados

Serão comparados modelos estatísticos, como o SARIMA (Equação 2.1), e modelos de aprendizado de máquina, como a floresta aleatória (Equação 2.2). O desempenho será avaliado pelo erro absoluto médio (*Mean Absolute Error*, MAE) e pela raiz do erro quadrático médio (*Root Mean Squared Error*, RMSE), definidos nas Equações (3.1) e (3.2):

$$\mathrm{MAE} = \frac{1}{n}\sum_{t=1}^{n} \left| y_t - \hat{y}_t \right|, \tag{3.1}$$

$$\mathrm{RMSE} = \sqrt{\frac{1}{n}\sum_{t=1}^{n} \left(y_t - \hat{y}_t \right)^2}, \tag{3.2}$$

em que $\hat{y}_t$ é a lentidão prevista para a hora t e n é o número de observações avaliadas.

EMS: Duas observações. (1) Use `\eqref` para citar equações, e não `\ref`: os parênteses fazem parte da numeração. (2) Defina o protocolo de validação: com séries temporais, a validação cruzada comum embaralha passado e futuro. Ver Bergmeir; Benítez (2012).

3.6 Aspectos éticos

A pesquisa utilizará apenas dados agregados de tráfego e meteorologia, sem informações que identifiquem pessoas, e, portanto, não envolverá seres humanos.

[1] Todos os dados deste trabalho são simulados, para fins didáticos.

3.7 Delimitações e limitações do estudo

1. O estudo se restringirá à cidade de São Paulo.
2. Serão consideradas apenas previsões de curto prazo.
3. [Definir o horizonte de previsão e a resolução temporal dos dados.]

4 RESULTADOS PRELIMINARES

Resumo do capítulo

Este capítulo apresenta a análise exploratória preliminar dos dados de lentidão de 2023, realizada para verificar a viabilidade da proposta. Os resultados indicam padrões horários e semanais bem definidos.

4.1 Análise exploratória preliminar

A Tabela 1 apresenta as estatísticas descritivas da extensão de lentidão em 2023, por tipo de dia.

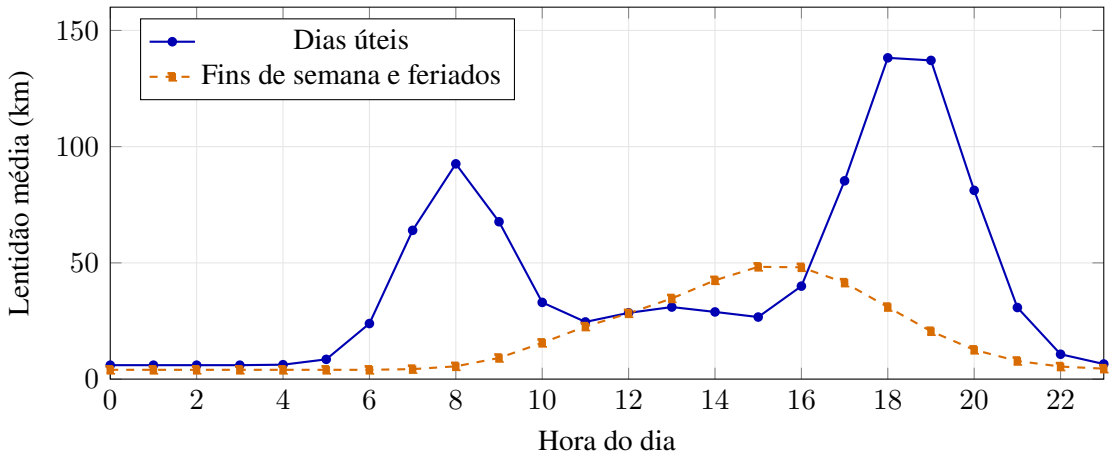
Tabela 1 – Estatísticas descritivas da extensão de lentidão (km), 2023

Tipo de dia	Horas	Média	Desvio-padrão	Máximo
Dias úteis	6.000	51,9	44,7	181,6
Fins de semana e feriados	2.760	18,2	15,0	92,8
Total	8.760	41,3	40,8	181,6

Fonte: Elaborada pela autora (2025).

O perfil horário médio, apresentado na Figura 2, mostra dois picos nos dias úteis, pela manhã e no fim da tarde, e um comportamento mais homogêneo nos fins de semana.

Figura 2 – Perfil horário médio da extensão de lentidão por tipo de dia, 2023



Fonte: Elaborada pela autora (2025).

Esses padrões indicam que a hora do dia e o tipo de dia serão variáveis relevantes para os modelos.

EMS: Bom ponto de partida. Para a qualificação, incluir uma prova de conceito com ao menos um modelo de referência (média histórica) e um modelo de aprendizado de máquina.

5 PLANOS PARA A CONTINUIDADE DO TRABALHO

Este capítulo apresenta as atividades previstas até a qualificação e até a defesa da dissertação.

5.1 Atividades previstas até a qualificação

Até a qualificação, prevê-se concluir a revisão sistemática da literatura, redefinir a lacuna e os objetivos a partir de seus resultados, construir a base de dados completa e realizar uma prova de conceito com os primeiros modelos.

5.2 Atividades previstas da qualificação à defesa

Após a qualificação, prevê-se incorporar as recomendações da banca, completar a comparação dos modelos, redigir os capítulos de resultados e conclusão e submeter um artigo científico com os principais achados.

5.3 Cronograma

O Quadro 3 consolida as atividades previstas.

Quadro 3 – Cronograma preliminar de atividades

		2025		2026				2027			
n	**ATIVIDADES**	**2º tri**	**4º tri**	**1º tri**	**2º tri**	**3º tri**	**4º tri**	**1º tri**	**2º tri**		
1	Revisão sistemática da literatura	■	■	■							
2	Construção da base de dados		■	■							
3	Prova de conceito			■							
4	**Exame de Qualificação**				■						
5	Comparação completa dos modelos					■					
6	Redação e submissão de artigo					■	■				
7	**Defesa da dissertação**							■			

Fonte: Elaborado pela autora (2025).

EMS: O cronograma usa trimestres, mas há colunas vazias no fim da tabela. Ajustar a estrutura e detalhar mais as atividades após a qualificação.

DECLARAÇÃO DE USO DE IA GENERATIVA

Não foram utilizadas ferramentas de inteligência artificial generativa na elaboração deste texto. A formulação do problema, a busca bibliográfica, a análise exploratória e todas as tabelas, quadros e figuras foram elaborados pela autora.

REFERÊNCIAS

ARRIETA, A. B. *et al.* Explainable artificial intelligence (XAI): concepts, taxonomies, opportunities and challenges toward responsible AI. **Information Fusion**, v. 58, p. 82–115, 2020. DOI: https://doi.org/10.1016/j.inffus.2019.12.012. Citado nas págs. A, 13.

BERGMEIR, C.; BENíTEZ, J. M. On the use of cross-validation for time series predictor evaluation. **Information Sciences**, v. 191, p. 192–213, 2012. DOI: https://doi.org/10.1016/j.ins.2011.12.028. Citado nas págs. A, 15.

BREIMAN, L. Random forests. **Machine Learning**, v. 45, n. 1, p. 5–32, 2001. DOI: https://doi.org/10.1023/A:1010933404324. Citado na pág. 12.

HEVNER, A. R. *et al.* Design science in information systems research. **MIS Quarterly**, v. 28, n. 1, p. 75–105, 2004. DOI: https://doi.org/10.2307/25148625. Citado nas págs. A, 14.

HYNDMAN, R. J.; ATHANASOPOULOS, G. **Forecasting: principles and practice**. 3. ed. Melbourne: OTexts, 2021. Disponível em: https://otexts.com/fpp3/. Acesso em: 10 mar. 2026. Citado na pág. 12.

KITCHENHAM, B.; CHARTERS, S. **Guidelines for performing systematic literature reviews in software engineering**. Keele, 2007. Citado na pág. 14.

LUNDBERG, S. M.; LEE, S.-I. A unified approach to interpreting model predictions. In: **Advances in Neural Information Processing Systems 30**. Long Beach: Curran Associates, 2017. p. 4765–4774. Citado nas págs. A, 13.

LV, Y. *et al.* Traffic flow prediction with big data: a deep learning approach. **IEEE Transactions on Intelligent Transportation Systems**, v. 16, n. 2, p. 865–873, 2015. DOI: https://doi.org/10.1109/TITS.2014.2345663. Citado na pág. 13.

PAGE, M. J. *et al.* The PRISMA 2020 statement: an updated guideline for reporting systematic reviews. **BMJ**, v. 372, p. n71, 2021. DOI: https://doi.org/10.1136/bmj.n71. Citado na pág. 14.

RUSSELL, S.; NORVIG, P. **Artificial intelligence: a modern approach**. 4. ed. Hoboken: Pearson, 2021. Citado na pág. 12.

VLAHOGIANNI, E. I.; KARLAFTIS, M. G.; GOLIAS, J. C. Short-term traffic forecasting: where we are and where we're going. **Transportation Research Part C: Emerging Technologies**, v. 43, p. 3–19, 2014. DOI: https://doi.org/10.1016/j.trc.2014.01.005. Citado nas págs. 10, 12, 13.

WILLIAMS, B. M.; HOEL, L. A. Modeling and forecasting vehicular traffic flow as a seasonal ARIMA process: theoretical basis and empirical results. **Journal of Transportation**

Engineering, v. 129, n. 6, p. 664–672, 2003. DOI: https://doi.org/10.1061/(ASCE)0733-947X(2003)129:6(664). Citado nas págs. 12, 13.

ZHANG, J. *et al.* Data-driven intelligent transportation systems: a survey. **IEEE Transactions on Intelligent Transportation Systems**, v. 12, n. 4, p. 1624–1639, 2011. DOI: https://doi.org/10.1109/TITS.2011.2158001. Citado nas págs. 10, 12.

APÊNDICE A – Expressão de busca preliminar

Quadro 4 – Expressão de busca preliminar para a base Scopus

```
TITLE-ABS-KEY(
  ("traffic congestion" OR "traffic flow")
  AND (forecast* OR predict*)
  AND ("machine learning" OR "random forest" OR "deep learning")
)
```

Busca exploratória realizada em 20/06/2025. A expressão será refinada na revisão sistemática.

Fonte: Elaborado pela autora (2025).

EMS: Incluir termos de explicabilidade na versão definitiva da busca, se a lacuna for redefinida.