UNIVERSIDADE NOVE DE JULHO – UNINOVE
PROGRAMA DE PÓS-GRADUAÇÃO EM INFORMÁTICA E GESTÃO DO CONHECIMENTO – PPGI

MARINA EXEMPLO DE OLIVEIRA

PREVISÃO EXPLICÁVEL DE CONGESTIONAMENTOS EM SÃO PAULO: UM SISTEMA INTELIGENTE DE APOIO À DECISÃO

São Paulo
2026

EXEMPLO DIDÁTICO: trabalho fictício, com dados simulados, elaborado para ilustrar o uso do modelo

MARINA EXEMPLO DE OLIVEIRA

PREVISÃO EXPLICÁVEL DE CONGESTIONAMENTOS EM SÃO PAULO: UM SISTEMA INTELIGENTE DE APOIO À DECISÃO

Texto de Qualificação de Mestrado apresentado ao Programa de Pós-Graduação em Informática e Gestão do Conhecimento (PPGI) da Universidade Nove de Julho (UNINOVE), como requisito parcial para a obtenção do grau de Mestra em Informática e Gestão do Conhecimento.

Orientador: Prof. Dr. Edson Melo de Souza

Data de ingresso: 03/2025
Linha de pesquisa: LP2 – Sistemas Inteligentes

São Paulo
2026

EXEMPLO DIDÁTICO: trabalho fictício, com dados simulados, elaborado para ilustrar o uso do modelo

RESUMO

Os congestionamentos urbanos impõem custos econômicos, ambientais e sociais às grandes metrópoles, e a cidade de São Paulo figura entre os casos mais emblemáticos no Brasil. Embora modelos de aprendizado de máquina apresentem bom desempenho na previsão de curto prazo das condições de tráfego, sua adoção por gestores públicos é limitada pela baixa transparência das previsões. Esta pesquisa tem como objetivo desenvolver e avaliar um sistema inteligente de previsão explicável da extensão de lentidão viária em São Paulo, com horizonte de uma hora, capaz de apoiar decisões operacionais. A pesquisa, de natureza aplicada e abordagem quantitativa, adota a *Design Science Research* como estratégia e organiza-se em quatro etapas: revisão sistemática da literatura, construção da base de dados, modelagem preditiva e explicação das previsões. Até o momento, a revisão sistemática, conduzida segundo a recomendação PRISMA 2020, resultou em 23 estudos analisados, e foi construída uma base horária que integra lentidão, condições meteorológicas, ocorrências e calendário, no período de 2022 a 2024. Na prova de conceito, a floresta aleatória reduziu o erro absoluto médio em 36,8% em relação à média histórica, na última partição de validação, superando também o modelo SARIMA. As próximas etapas compreendem a avaliação de modelos de *boosting*, o cálculo das explicações com valores SHAP e o desenvolvimento do protótipo de painel de apoio à decisão.

Palavras-chave: sistemas inteligentes; previsão de tráfego; aprendizado de máquina; inteligência artificial explicável; mobilidade urbana.

EXEMPLO DIDÁTICO: trabalho fictício, com dados simulados, elaborado para ilustrar o uso do modelo

ABSTRACT

Urban congestion imposes economic, environmental and social costs on large metropolitan areas, and the city of São Paulo is among the most emblematic cases in Brazil. Although machine learning models perform well in short-term traffic forecasting, their adoption by public managers is limited by the low transparency of their predictions. This research aims to develop and evaluate an intelligent system for the explainable forecasting of traffic congestion length in São Paulo, with a one-hour horizon, capable of supporting operational decisions. The research, applied in nature and quantitative in approach, adopts Design Science Research as its strategy and is organised into four stages: systematic literature review, dataset construction, predictive modelling and explanation of the predictions. So far, the systematic review, conducted according to the PRISMA 2020 statement, has resulted in 23 analysed studies, and an hourly dataset integrating congestion, weather conditions, incidents and calendar information from 2022 to 2024 has been built. In the proof of concept, the random forest reduced the mean absolute error by 36.8% relative to the historical mean in the last validation fold, also outperforming the SARIMA model. The next stages comprise the evaluation of boosting models, the computation of SHAP explanations and the development of the decision-support dashboard prototype.

Keywords: intelligent systems; traffic forecasting; machine learning; explainable artificial intelligence; urban mobility.

EXEMPLO DIDÁTICO: trabalho fictício, com dados simulados, elaborado para ilustrar o uso do modelo

LISTA DE FIGURAS

Figura 1 – Desenho da pesquisa e vínculo das etapas com os objetivos específicos . . 20
Figura 2 – Fluxograma do processo de seleção sistemática conforme a recomendação PRISMA 2020 21
Figura 3 – Representação esquemática dos corredores viários analisados 22

Figura 4 – Perfil horário médio da extensão de lentidão por tipo de dia 26
Figura 5 – Erro absoluto médio dos modelos avaliados na prova de conceito 27

EXEMPLO DIDÁTICO: trabalho fictício, com dados simulados, elaborado para ilustrar o uso do modelo

LISTA DE QUADROS

Quadro 1 – Trabalhos de referência para a previsão explicável de tráfego 18

Quadro 2 – Cronograma de atividades até a defesa 30
Quadro 3 – Expressão de busca aplicada na base Scopus 34
Quadro 4 – Expressão de busca aplicada na base Web of Science 34
Quadro 5 – Dicionário de variáveis da base horária 35

EXEMPLO DIDÁTICO: trabalho fictício, com dados simulados, elaborado para ilustrar o uso do modelo

LISTA DE TABELAS

Tabela 1 – Estatísticas descritivas da extensão de lentidão (km), 2022 a 2024 26
Tabela 2 – Desempenho preliminar dos modelos na última partição de validação (2º semestre de 2023) 27

LISTA DE ABREVIATURAS E SIGLAS

CNS	Conselho Nacional de Saúde
GB	*Gradient Boosting*
IA	Inteligência Artificial
ITS	*Intelligent Transportation Systems* (Sistemas Inteligentes de Transporte)
LGPD	Lei Geral de Proteção de Dados Pessoais
LIME	*Local Interpretable Model-agnostic Explanations*
MAE	*Mean Absolute Error* (erro absoluto médio)
PRISMA	*Preferred Reporting Items for Systematic Reviews and Meta-Analyses*
RF	*Random Forest* (floresta aleatória)
RMSE	*Root Mean Squared Error* (raiz do erro quadrático médio)
SARIMA	*Seasonal AutoRegressive Integrated Moving Average*
SHAP	*SHapley Additive exPlanations*
XAI	*Explainable Artificial Intelligence* (Inteligência Artificial Explicável)

LISTA DE SÍMBOLOS

p, d, q	Ordens não sazonais do modelo SARIMA
P, D, Q	Ordens sazonais do modelo SARIMA
s	Período sazonal
ϕ_p, Φ_P	Polinômios autorregressivos não sazonal e sazonal
B	Operador de defasagem, $By_t = y_{t-1}$
y_t	Extensão total de lentidão observada na hora t (km)
θ_q, Θ_Q	Polinômios de médias móveis não sazonal e sazonal
ε_t	Termo de erro aleatório
t	Índice temporal (hora)
$\mathbf{x}$	Vetor de variáveis preditoras
T	Número de árvores da floresta aleatória
h_b	Árvore de decisão b
F_m	Modelo aditivo após a iteração m do *boosting*
ν	Taxa de aprendizado
j	Índice de uma variável preditora (jogador)
$\phi_j(v)$	Valor de Shapley da variável j
v	Função característica
S	Coalizão de variáveis que não contém j
N	Conjunto de variáveis preditoras
g	Modelo explicativo aditivo
ϕ_0	Valor de base (previsão média)
$\mathbf{z}'$	Vetor binário de presença das variáveis
$\hat{y}_t$	Extensão de lentidão prevista para a hora t (km)
n	Número de observações do conjunto avaliado
$\bar{y}$	Média das observações
λ	Vetor de hiperparâmetros
Λ	Espaço de busca dos hiperparâmetros
K	Número de partições da validação com origem móvel
r	Índice de uma partição de validação
G	Ganho relativo de desempenho (%)

EXEMPLO DIDÁTICO: trabalho fictício, com dados simulados, elaborado para ilustrar o uso do modelo

SUMÁRIO

1 INTRODUÇÃO 11
1.1 Contextualização 11
1.2 Problema de pesquisa 12
1.3 Objetivos 12
1.3.1 Objetivo geral 12
1.3.2 Objetivos específicos 12
1.4 Justificativa 13
1.5 Contribuições esperadas 13
1.6 Organização do trabalho 13

2 FUNDAMENTAÇÃO TEÓRICA 15
2.1 Sistemas inteligentes de transporte 15
2.2 Previsão de tráfego de curto prazo 15
2.3 Modelos baseados em conjuntos de árvores 16
2.4 Inteligência artificial explicável 17
2.5 Trabalhos relacionados 17

3 METODOLOGIA 19
3.1 Visão geral 19
3.2 Classificação da pesquisa 19
3.3 Desenho da pesquisa 19
3.4 Procedimentos de levantamento da literatura 20
3.5 Procedimentos de coleta de dados 21
3.6 Procedimentos de análise de dados 22
3.6.1 Modelos avaliados 22
3.6.2 Métricas de avaliação 23
3.6.3 Protocolo de validação 23
3.6.4 Explicação das previsões 24
3.7 Aspectos éticos 24
3.8 Delimitações e limitações do estudo 24

4 RESULTADOS PRELIMINARES 26
4.1 Caracterização da base de dados 26
4.2 Prova de conceito 27
4.3 Discussão dos resultados preliminares 27

5 PLANOS PARA A CONTINUIDADE DO TRABALHO 29
5.1 Atividades previstas até a defesa 29
5.2 Cronograma 29

EXEMPLO DIDÁTICO: trabalho fictício, com dados simulados, elaborado para ilustrar o uso do modelo

DECLARAÇÃO DE USO DE IA GENERATIVA 31

REFERÊNCIAS 32

APÊNDICE A – Expressões de busca da revisão sistemática 34

APÊNDICE B – Dicionário de variáveis 35

1 INTRODUÇÃO

1.1 Contextualização

A mobilidade urbana constitui um dos desafios estruturais das grandes metrópoles. O crescimento da frota de veículos, a concentração de atividades econômicas em poucas regiões e a limitada capacidade de expansão da malha viária produzem congestionamentos recorrentes, com impactos sobre o tempo de deslocamento, o consumo de combustível, a emissão de poluentes e a qualidade de vida da população. Na cidade de São Paulo, o fenômeno assume escala particularmente expressiva, o que torna o tema objeto permanente da agenda pública e da pesquisa aplicada.

Nas últimas décadas, a disponibilidade de grandes volumes de dados de sensores, câmeras, dispositivos móveis e sistemas de monitoramento deu origem aos chamados Sistemas Inteligentes de Transporte (*Intelligent Transportation Systems*, ITS), que buscam transformar esses dados em informação útil para a operação e o planejamento do tráfego (Zhang *et al.*, 2011). Entre as funções desses sistemas, a previsão de curto prazo das condições de tráfego ocupa posição central, pois permite antecipar congestionamentos e acionar medidas preventivas, como a reprogramação semafórica, o reposicionamento de equipes de campo e a comunicação com os usuários (Vlahogianni; Karlaftis; Golias, 2014).

Os métodos de previsão evoluíram de modelos estatísticos de séries temporais, como os modelos autorregressivos integrados de médias móveis com componente sazonal (Williams; Hoel, 2003), para técnicas de aprendizado de máquina e aprendizado profundo, capazes de capturar relações não lineares entre múltiplas variáveis (Lv *et al.*, 2015). Esse ganho de capacidade preditiva, contudo, veio acompanhado de menor transparência. Modelos baseados em conjuntos de árvores ou em redes neurais produzem previsões precisas, mas não explicam, por si sós, *por que* determinado congestionamento é esperado. Para um gestor público, que precisa justificar decisões e alocar recursos escassos, essa opacidade representa uma barreira concreta à adoção (Arrieta *et al.*, 2020).

A Inteligência Artificial Explicável (*Explainable Artificial Intelligence*, XAI) surgiu como resposta a essa limitação, reunindo métodos que tornam inteligíveis as decisões de modelos complexos. Entre eles, destacam-se as explicações baseadas em valores de Shapley, que atribuem a cada variável preditora uma contribuição para a previsão individual, com fundamentação na teoria dos jogos cooperativos (Lundberg; Lee, 2017). Esta dissertação situa-se na interseção entre esses dois campos: a previsão de tráfego de curto prazo e a explicabilidade de modelos de aprendizado de máquina.

EXEMPLO DIDÁTICO: trabalho fictício, com dados simulados, elaborado para ilustrar o uso do modelo

1.2 Problema de pesquisa

A literatura sobre previsão de tráfego concentrou-se historicamente na acurácia dos modelos, e a explicabilidade das previsões permanece tratada de forma secundária (Vlahogianni; Karlaftis; Golias, 2014). Os estudos que incorporam métodos de XAI a esse domínio são recentes e, em sua maioria, avaliam a explicação como produto acessório, sem examinar de que modo ela pode ser apresentada ao gestor para apoiar decisões operacionais. Além disso, há poucos trabalhos dedicados ao contexto de metrópoles brasileiras, cujas dinâmicas de tráfego são fortemente influenciadas por fatores locais, como chuvas intensas de verão, calendário de feriados e eventos de grande porte.

Lacuna de Pesquisa. Faltam estudos que integrem previsão de curto prazo da lentidão viária e explicações locais das previsões em um sistema de apoio à decisão avaliado no contexto de uma metrópole brasileira.

Pergunta de Pesquisa. Em que medida um sistema inteligente baseado em aprendizado de máquina e valores de Shapley é capaz de prever com acurácia a extensão de lentidão viária em São Paulo, com horizonte de uma hora, e de explicar de forma inteligível os fatores que determinam cada previsão?

1.3 Objetivos

1.3.1 Objetivo geral

Desenvolver e avaliar um sistema inteligente de previsão explicável da extensão de lentidão viária na cidade de São Paulo, com horizonte de uma hora, voltado ao apoio à decisão na gestão do tráfego.

1.3.2 Objetivos específicos

1. Mapear, por meio de revisão sistemática da literatura, os métodos de previsão de tráfego de curto prazo e as abordagens de explicabilidade aplicadas a esse domínio.
2. Estruturar uma base de dados horária que integre lentidão viária, condições meteorológicas, ocorrências e calendário.
3. Comparar o desempenho de modelos estatísticos e de aprendizado de máquina na previsão da extensão de lentidão.
4. Explicar as previsões do modelo de melhor desempenho por meio de valores SHAP e incorporá-las a um protótipo de painel de apoio à decisão.

EXEMPLO DIDÁTICO: trabalho fictício, com dados simulados, elaborado para ilustrar o uso do modelo

1.4 Justificativa

Do ponto de vista teórico, o trabalho contribui para a aproximação entre duas linhas de pesquisa que evoluíram de forma relativamente independente: a previsão de tráfego e a explicabilidade de modelos. Do ponto de vista prático, a previsão antecipada da lentidão, acompanhada da indicação dos fatores que a determinam, permite que equipes de operação de tráfego atuem de modo preventivo e justifiquem tecnicamente suas decisões. No plano social, a redução de congestionamentos tem efeitos diretos sobre o tempo de deslocamento e a qualidade do ar, com benefícios distribuídos por toda a população urbana.

1.5 Contribuições esperadas

Espera-se que este trabalho contribua com:

- um panorama sistematizado da literatura sobre previsão explicável de tráfego, com a identificação de lacunas e tendências;
- um protocolo reprodutível de comparação de modelos sob validação temporal, adequado a séries com forte sazonalidade;
- evidências sobre o peso relativo de fatores temporais, meteorológicos e operacionais na formação da lentidão em São Paulo;
- um protótipo de painel que apresenta, para cada previsão, a decomposição das contribuições dos fatores, como referência para sistemas de apoio à decisão no setor público.

1.6 Organização do trabalho

Além desta Introdução, o trabalho está estruturado em quatro capítulos:

- Capítulo 2 (**Fundamentação teórica**). Apresenta os conceitos de sistemas inteligentes de transporte, os métodos de previsão de tráfego, os modelos baseados em árvores e as técnicas de explicabilidade, além dos trabalhos relacionados.
- Capítulo 3 (**Metodologia**). Descreve a classificação e o desenho da pesquisa, o protocolo da revisão sistemática, a construção da base de dados, os modelos avaliados e os critérios de validação.
- Capítulo 4 (**Resultados preliminares**). Apresenta a caracterização da base de dados e os resultados da prova de conceito com os primeiros modelos avaliados.
- Capítulo 5 (**Planos para a continuidade do trabalho**). Detalha as atividades previstas até a defesa, consolidadas em cronograma.

EXEMPLO DIDÁTICO: trabalho fictício, com dados simulados, elaborado para ilustrar o uso do modelo

Complementam o texto a Declaração de Uso de IA Generativa, as Referências e os Apêndices A e B.

EXEMPLO DIDÁTICO: trabalho fictício, com dados simulados, elaborado para ilustrar o uso do modelo

2 FUNDAMENTAÇÃO TEÓRICA

Resumo do capítulo

Este capítulo apresenta os fundamentos que sustentam a pesquisa. Inicia-se pelos sistemas inteligentes de transporte e pela previsão de tráfego de curto prazo, com destaque para os modelos sazonais de séries temporais. Em seguida, são apresentados os modelos de aprendizado de máquina baseados em conjuntos de árvores e os métodos de inteligência artificial explicável, em particular os valores de Shapley e o método SHAP. O capítulo encerra-se com a análise dos trabalhos relacionados e com a delimitação da lacuna que orienta a investigação.

A fundamentação teórica organiza-se em quatro eixos, que acompanham a sequência dos objetivos específicos: sistemas inteligentes de transporte, previsão de tráfego, modelos baseados em árvores e explicabilidade. As fontes discutidas foram recuperadas segundo o protocolo descrito na Seção 3.4.

2.1 Sistemas inteligentes de transporte

Um sistema inteligente pode ser compreendido como um agente que percebe seu ambiente e age de modo a maximizar o alcance de seus objetivos (Russell; Norvig, 2021). No domínio da mobilidade, os ITS aplicam essa concepção à rede viária: coletam dados sobre o estado do tráfego, processam-nos por meio de modelos analíticos e apoiam, ou executam, ações de controle e informação. Zhang *et al.* (2011) caracterizam a transição para os ITS orientados por dados, nos quais a disponibilidade massiva de registros de sensores, veículos e dispositivos móveis desloca o foco dos modelos físicos de fluxo para modelos aprendidos a partir dos dados.

Nesta pesquisa, adota-se o entendimento de sistema inteligente como um artefato computacional que integra dados heterogêneos, produz previsões e as comunica ao decisor humano de forma inteligível. Essa delimitação é relevante porque desloca a avaliação do sistema da acurácia isolada para a utilidade da informação no processo decisório.

2.2 Previsão de tráfego de curto prazo

A previsão de tráfego de curto prazo refere-se à estimativa das condições da via, como fluxo, velocidade ou extensão de congestionamento, em horizontes que variam de poucos minutos a algumas horas. Em revisão abrangente, Vlahogianni; Karlaftis; Golias (2014) observam que o campo amadureceu na direção de modelos orientados por dados, mas apontam desafios persistentes, como a incorporação de fatores contextuais e a avaliação dos modelos em condições operacionais reais.

Entre os modelos estatísticos, destacam-se os modelos SARIMA, que representam a série como combinação de componentes autorregressivos, de médias móveis e sazonais. Williams; Hoel (2003) fundamentaram teoricamente o uso desses modelos para o fluxo veicular,

EXEMPLO DIDÁTICO: trabalho fictício, com dados simulados, elaborado para ilustrar o uso do modelo

cuja periodicidade diária e semanal se ajusta à estrutura sazonal. Na notação de Hyndman; Athanasopoulos (2021), um modelo SARIMA$(p,d,q)(P,D,Q)_s$ é expresso pela Equação (2.1):

$$\phi_p(B)\,\Phi_P(B^s)\,(1-B)^d\,(1-B^s)^D\,y_t = \theta_q(B)\,\Theta_Q(B^s)\,\varepsilon_t, \tag{2.1}$$

em que y_t é o valor da série no instante t, B é o operador de defasagem ($By_t = y_{t-1}$), s é o período sazonal, ϕ_p e Φ_P são os polinômios autorregressivos não sazonal e sazonal, θ_q e Θ_Q são os polinômios de médias móveis correspondentes, d e D são as ordens de diferenciação e ε_t é o termo de erro aleatório.

Os modelos de aprendizado profundo ampliaram a capacidade de capturar padrões complexos. Lv *et al.* (2015) demonstraram que autocodificadores empilhados superam modelos tradicionais na previsão do fluxo em grandes volumes de dados. Esses modelos, entretanto, exigem grandes bases de treinamento e oferecem pouca transparência, o que motiva o interesse por alternativas baseadas em árvores, que combinam bom desempenho em dados tabulares com maior facilidade de explicação.

2.3 Modelos baseados em conjuntos de árvores

As florestas aleatórias (*Random Forest*, RF) combinam múltiplas árvores de decisão treinadas sobre amostras *bootstrap* dos dados e subconjuntos aleatórios das variáveis (Breiman, 2001). Para problemas de regressão, a previsão da floresta corresponde à média das previsões das árvores individuais, conforme a Equação (2.2):

$$\hat{f}_{\mathrm{RF}}(\mathbf{x}) = \frac{1}{T}\sum_{b=1}^{T} h_b(\mathbf{x}), \tag{2.2}$$

em que $\mathbf{x}$ é o vetor de variáveis preditoras, T é o número de árvores e h_b é a b-ésima árvore.

O *boosting* por gradiente (*Gradient Boosting*, GB), por sua vez, constrói o modelo de forma sequencial, adicionando a cada iteração uma árvore ajustada aos resíduos do modelo anterior (Friedman, 2001). A atualização é dada pela Equação (2.3):

$$F_m(\mathbf{x}) = F_{m-1}(\mathbf{x}) + \nu\, h_m(\mathbf{x}), \tag{2.3}$$

em que F_m é o modelo após a iteração m, h_m é a árvore ajustada ao gradiente negativo da função de perda e $\nu \in (0,1]$ é a taxa de aprendizado. O XGBoost aperfeiçoa essa formulação com regularização explícita da complexidade das árvores e otimizações de desempenho computacional, o que o tornou referência em problemas de dados tabulares (Chen; Guestrin, 2016).

EXEMPLO DIDÁTICO: trabalho fictício, com dados simulados, elaborado para ilustrar o uso do modelo

2.4 Inteligência artificial explicável

Arrieta *et al.* (2020) definem a XAI como o conjunto de técnicas que produzem modelos ou explicações compreensíveis para uma audiência específica, e distinguem os modelos transparentes por concepção das técnicas aplicadas posteriormente a modelos complexos. Entre estas últimas, o LIME (*Local Interpretable Model-agnostic Explanations*) aproxima o comportamento do modelo na vizinhança de uma previsão por um modelo linear simples (Ribeiro; Singh; Guestrin, 2016). Essa aproximação local, embora intuitiva, pode variar conforme o procedimento de amostragem, o que compromete a estabilidade das explicações (Molnar, 2022).

Uma alternativa com garantias teóricas decorre da teoria dos jogos cooperativos. Shapley (1953) propôs um critério de repartição do ganho de uma coalizão entre seus participantes, segundo o qual a contribuição do jogador j corresponde à média ponderada de suas contribuições marginais a todas as coalizões possíveis, conforme a Equação (2.4):

$$\phi_j(v) = \sum_{S \subseteq N \setminus \{j\}} \frac{|S|!\ (|N| - |S| - 1)!}{|N|!} \Big[v\left(S \cup \{j\}\right) - v(S) \Big], \tag{2.4}$$

em que N é o conjunto de jogadores, S é uma coalizão que não contém j e v é a função característica, que associa a cada coalizão o ganho por ela obtido.

Lundberg; Lee (2017) transpuseram essa formulação para a explicação de modelos preditivos, tratando as variáveis como jogadores e a previsão como o ganho a ser repartido. O método resultante, denominado SHAP (*SHapley Additive exPlanations*), expressa cada previsão como a soma de um valor de base e das contribuições das variáveis, conforme a Equação (2.5):

$$g(\mathbf{z}') = \phi_0 + \sum_{j \in N} \phi_j \, z'_j, \tag{2.5}$$

em que g é o modelo explicativo, ϕ_0 é o valor de base, correspondente à previsão média, e $z'_j \in \{0, 1\}$ indica a presença da variável j. Essa propriedade aditiva permite apresentar ao decisor, de forma direta, quanto cada fator elevou ou reduziu a previsão. Para modelos baseados em árvores, Lundberg *et al.* (2020) desenvolveram o algoritmo TreeSHAP, que calcula os valores exatos em tempo polinomial e viabiliza a explicação de grandes volumes de previsões.

2.5 Trabalhos relacionados

A revisão sistemática descrita na Seção 3.4 resultou em 23 estudos analisados. O Quadro 1 apresenta os trabalhos de maior influência sobre as escolhas desta pesquisa, comparados segundo o foco metodológico e a principal contribuição.

EXEMPLO DIDÁTICO: trabalho fictício, com dados simulados, elaborado para ilustrar o uso do modelo

Quadro 1 – Trabalhos de referência para a previsão explicável de tráfego

ID	Referência	Foco metodológico	Principal contribuição
E01	Williams; Hoel (2003)	Modelagem SARIMA do fluxo veicular.	Fundamentação teórica da sazonalidade do tráfego em modelos de séries temporais.
E02	Zhang *et al.* (2011)	Revisão sobre ITS orientados por dados.	Caracterização da transição para sistemas baseados em dados massivos.
E03	Vlahogianni; Karlaftis; Golias (2014)	Revisão sobre previsão de curto prazo.	Agenda de pesquisa com ênfase em contexto e avaliação operacional.
E04	Lv *et al.* (2015)	Aprendizado profundo com autocodificadores empilhados.	Ganho de acurácia em grandes volumes de dados de fluxo.
E05	Chen; Guestrin (2016)	*Boosting* por gradiente regularizado.	Algoritmo escalável e de alto desempenho em dados tabulares.
E06	Lundberg *et al.* (2020)	Explicações SHAP exatas para árvores.	Algoritmo TreeSHAP e explicações locais e globais consistentes.

Fonte: Elaborado pela autora (2026).

A comparação evidencia dois movimentos paralelos. De um lado, a previsão de tráfego avançou em acurácia, dos modelos sazonais (E01) ao aprendizado profundo (E04). De outro, os métodos de explicação ganharam fundamentação teórica e eficiência computacional (E06). Os estudos que combinam ambos os movimentos, entre os 23 analisados, tratam a explicação como resultado complementar e não a integram a um artefato voltado ao decisor. Essa constatação reforça a lacuna anunciada na Seção 1.2 e justifica a proposta de um sistema que articule previsão, explicação e apresentação ao gestor.

EXEMPLO DIDÁTICO: trabalho fictício, com dados simulados, elaborado para ilustrar o uso do modelo

3 METODOLOGIA

Resumo do capítulo

Este capítulo descreve os procedimentos adotados e previstos para responder à pergunta de pesquisa. A investigação, de natureza aplicada e abordagem quantitativa, segue a estratégia da Design Science Research e organiza-se em quatro etapas: revisão sistemática da literatura, construção da base de dados, modelagem e avaliação preditiva, e explicação das previsões com desenvolvimento do artefato. São detalhados as fontes de dados, as variáveis, os modelos comparados, as métricas de avaliação, o protocolo de validação temporal e os aspectos éticos.

3.1 Visão geral

A pesquisa é conduzida de modo a vincular cada etapa a um objetivo específico. A revisão da literatura, já concluída, orienta a escolha dos modelos e das variáveis; a construção da base fornece os dados para treinamento e teste; a modelagem identifica o modelo de melhor desempenho; e a etapa de explicação transforma as previsões em informação utilizável pelo decisor. As etapas 1 e 2 estão concluídas, e a etapa 3 encontra-se em andamento, com resultados parciais no Capítulo 4. As seções seguintes detalham cada uma dessas etapas.

3.2 Classificação da pesquisa

Quanto à natureza, a pesquisa é aplicada, pois busca gerar conhecimento voltado à solução de um problema concreto da gestão do tráfego. Quanto à abordagem, é quantitativa, uma vez que os modelos são avaliados por métricas numéricas de erro. Quanto aos objetivos, é explicativa, ao investigar os fatores que determinam a lentidão viária. Quanto aos procedimentos, combina pesquisa bibliográfica, na forma de revisão sistemática, e experimentação computacional.

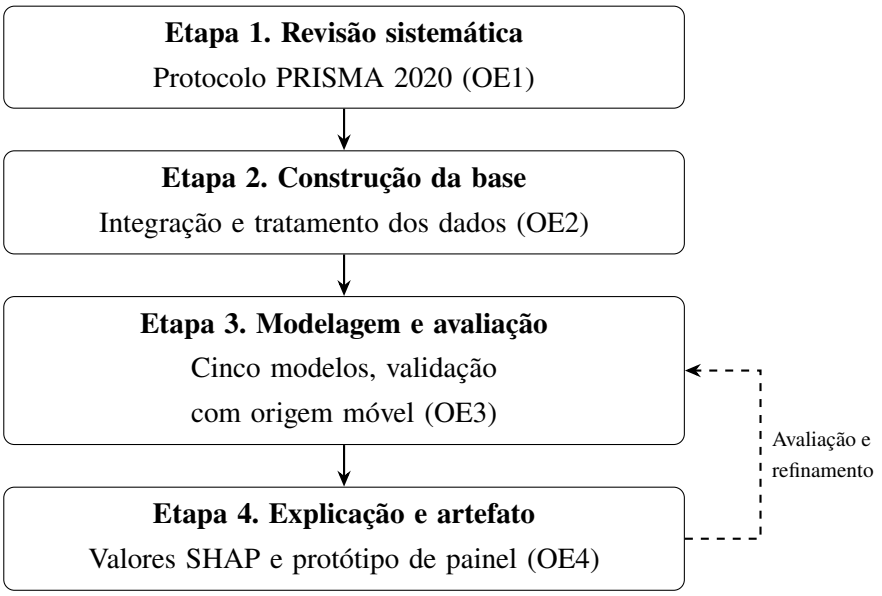
A estratégia geral adotada é a *Design Science Research*, que orienta a construção e a avaliação de artefatos destinados a resolver problemas relevantes, com rigor na fundamentação e na avaliação (Hevner *et al.*, 2004). O artefato desta pesquisa é o sistema de previsão explicável, composto pelo modelo preditivo, pelo módulo de explicação e pelo protótipo de painel.

3.3 Desenho da pesquisa

A Figura 1 apresenta as quatro etapas da pesquisa e sua correspondência com os objetivos específicos (OE). A seta tracejada indica o ciclo de avaliação e refinamento característico da *Design Science Research*, no qual os resultados da explicação retroalimentam a seleção de variáveis e a configuração dos modelos.

EXEMPLO DIDÁTICO: trabalho fictício, com dados simulados, elaborado para ilustrar o uso do modelo

Figura 1 – Desenho da pesquisa e vínculo das etapas com os objetivos específicos



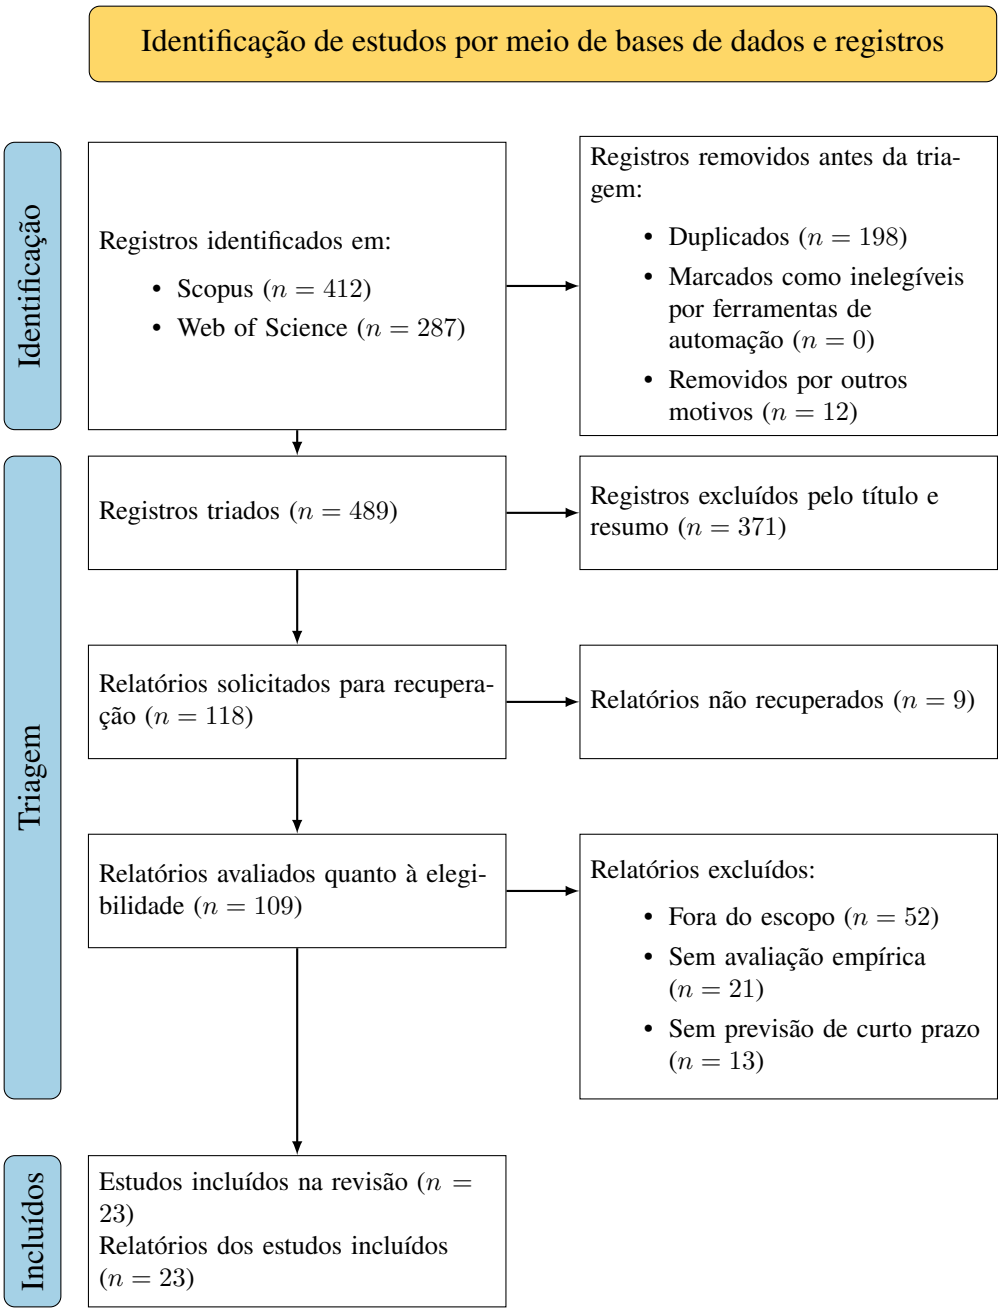
Fonte: Elaborada pela autora (2026).

3.4 Procedimentos de levantamento da literatura

A revisão sistemática seguiu as diretrizes de Kitchenham; Charters (2007) para a condução e a recomendação PRISMA 2020 para o relato (Page *et al.*, 2021). As buscas foram realizadas nas bases Scopus e Web of Science, em maio de 2025, com expressões que combinam termos de tráfego, previsão, aprendizado de máquina e explicabilidade, apresentadas integralmente no Apêndice A. Foram incluídos artigos publicados entre 2015 e 2025, em inglês, com avaliação empírica de modelos de previsão de curto prazo. O fluxo de seleção está representado na Figura 2.

EXEMPLO DIDÁTICO: trabalho fictício, com dados simulados, elaborado para ilustrar o uso do modelo

Figura 2 – Fluxograma do processo de seleção sistemática conforme a recomendação PRISMA 2020



Fonte: Elaborada pela autora (2026).

3.5 Procedimentos de coleta de dados

A base de dados integra quatro fontes, organizadas em resolução horária para o período de 1º de janeiro de 2022 a 31 de dezembro de 2024, o que totaliza 26.304 observações[1]:

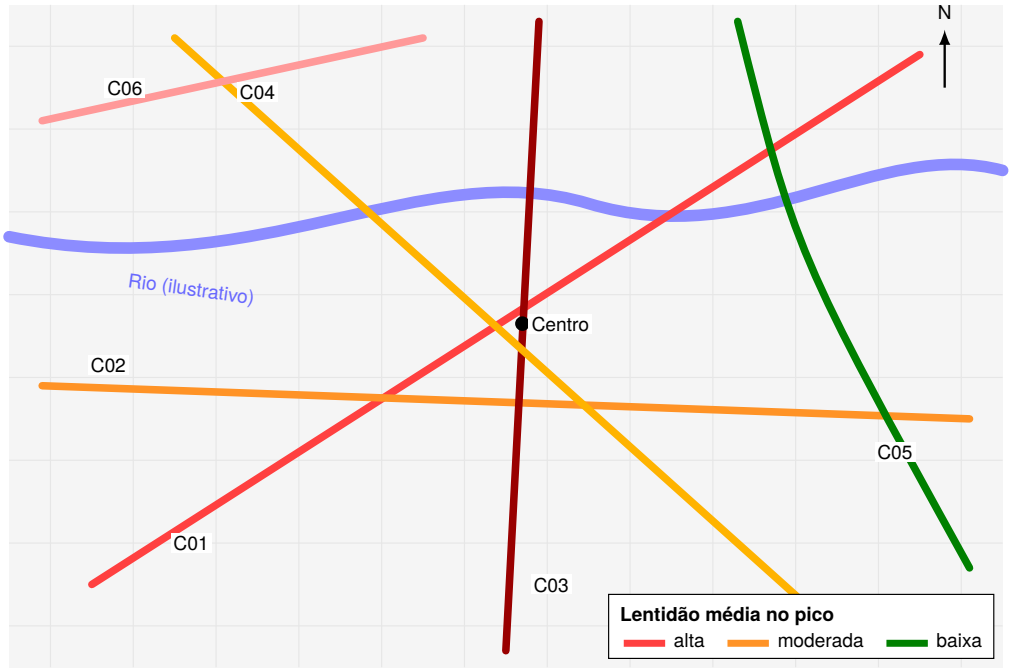
1. **Lentidão viária**: extensão total de lentidão monitorada nos corredores da cidade, em quilômetros, variável a ser prevista;

[1] Todos os dados deste trabalho são simulados. A base foi gerada para fins didáticos e reproduz apenas a estrutura de dados que um estudo real sobre o tema utilizaria.

2. **Condições meteorológicas**: precipitação horária (mm) e temperatura do ar (°C);
3. **Ocorrências**: número de ocorrências viárias ativas, como acidentes e veículos quebrados;
4. **Calendário**: hora do dia, dia da semana, feriados e eventos de grande porte.

A Figura 3 ilustra, de forma esquemática, os seis corredores considerados na análise por corredor, utilizada na etapa exploratória.

Figura 3 – Representação esquemática dos corredores viários analisados



Fonte: Elaborada pela autora (2026).

O tratamento dos dados compreende a remoção de registros inconsistentes, a imputação de valores ausentes (1,8% das observações) por interpolação linear restrita a lacunas de até três horas e a construção da variável de defasagem, que corresponde à lentidão observada na hora anterior. O dicionário completo das variáveis encontra-se no Apêndice B.

3.6 Procedimentos de análise de dados

3.6.1 Modelos avaliados

São comparados cinco modelos de complexidade crescente: (i) a média histórica para a mesma hora e o mesmo tipo de dia, adotada como referência; (ii) o modelo SARIMA, definido na Equação (2.1); (iii) a floresta aleatória, definida na Equação (2.2); (iv) o *boosting* por gradiente, definido na Equação (2.3); e (v) o XGBoost (Chen; Guestrin, 2016). Os modelos

são implementados em Python, com as bibliotecas *statsmodels*, *scikit-learn* (Pedregosa *et al.*, 2011), *xgboost* e *shap*, com versões registradas no repositório do projeto.

3.6.2 Métricas de avaliação

O desempenho é avaliado no conjunto de teste por três métricas complementares. O erro absoluto médio (*Mean Absolute Error*, MAE), expresso na mesma unidade da variável prevista, é dado pela Equação (3.1):

$$\mathrm{MAE} = \frac{1}{n}\sum_{t=1}^{n} \left| y_t - \hat{y}_t \right|, \tag{3.1}$$

em que $\hat{y}_t$ é a extensão de lentidão prevista para a hora t e n é o número de observações avaliadas. A raiz do erro quadrático médio (*Root Mean Squared Error*, RMSE), que penaliza com mais intensidade os erros elevados, e o coeficiente de determinação (R^2) são calculados conforme as Equações (3.2) e (3.3):

$$\mathrm{RMSE} = \sqrt{\frac{1}{n}\sum_{t=1}^{n} \left(y_t - \hat{y}_t \right)^2}, \tag{3.2}$$

$$R^2 = 1 - \frac{\sum_{t=1}^{n} \left(y_t - \hat{y}_t \right)^2}{\sum_{t=1}^{n} \left(y_t - \bar{y} \right)^2}, \tag{3.3}$$

em que $\bar{y}$ é a média das observações. Para facilitar a comparação com a referência, calcula-se ainda o ganho relativo G, definido na Equação (3.4):

$$G = \frac{\mathrm{MAE}_{\text{ref}} - \mathrm{MAE}_{\text{modelo}}}{\mathrm{MAE}_{\text{ref}}} \times 100\%. \tag{3.4}$$

3.6.3 Protocolo de validação

Como a variável prevista é uma série temporal, a validação cruzada convencional, que embaralha as observações, produziria estimativas otimistas ao permitir que o modelo aprendesse com dados futuros. Adota-se, por isso, a validação com origem móvel recomendada por Bergmeir; Benítez (2012). Os dados de 2022 e 2023 (17.520 horas) são reservados para treinamento e ajuste, e os de 2024 (8.784 horas) para o teste final, a ser utilizado uma única vez, após a definição dos modelos. O ajuste dos hiperparâmetros λ de cada modelo segue a Equação (3.5):

$$\hat{\lambda} = \arg\min_{\lambda \in \Lambda} \; \frac{1}{K}\sum_{r=1}^{K} \mathrm{MAE}_r(\lambda), \tag{3.5}$$

onde Λ é o espaço de busca, $K = 6$ é o número de partições e MAE_r é o erro na r-ésima partição de validação. O procedimento está descrito no Algoritmo 1.

Algoritmo 1: Validação com origem móvel para ajuste de hiperparâmetros

Entrada: série de treinamento $\{(\mathbf{x}_t, y_t)\}$; espaço de busca Λ; número de partições K
Saída: hiperparâmetros selecionados $\hat{\lambda}$

para cada $\lambda \in \Lambda$ **faça**
  para $r \leftarrow 1$ **até** K **faça**
    definir o período de treino até a origem r e o período de validação seguinte;
    ajustar o modelo com λ no período de treino;
    calcular $\mathrm{MAE}_r(\lambda)$ no período de validação;
  calcular a média dos K erros;
retorna λ com menor erro médio;

3.6.4 Explicação das previsões

A contribuição de cada variável para as previsões do modelo de melhor desempenho será estimada pelos valores de Shapley, definidos na Equação (2.4), na forma aditiva da Equação (2.5). Como o cálculo exato exige avaliar $2^{|N|-1}$ coalizões para cada variável, será adotado o algoritmo TreeSHAP (Lundberg *et al.*, 2020), que obtém os valores exatos em tempo polinomial para modelos baseados em árvores. As explicações serão analisadas em dois níveis: global, pela média dos valores absolutos de cada variável, e local, pela decomposição de previsões individuais apresentada no painel.

3.7 Aspectos éticos

A pesquisa utiliza exclusivamente dados agregados de tráfego, meteorologia e calendário, sem qualquer informação que identifique pessoas. Por não envolver seres humanos, direta ou indiretamente, não se enquadra nas hipóteses de submissão ao sistema de Comitês de Ética em Pesquisa previstas nas Resoluções do Conselho Nacional de Saúde (CNS) n.º 466/2012 e n.º 510/2016, nem envolve tratamento de dados pessoais nos termos da Lei Geral de Proteção de Dados Pessoais (LGPD). O uso dos dados observa os termos de autorização formal obtida junto à instituição parceira.

3.8 Delimitações e limitações do estudo

O estudo delimita-se à previsão da extensão total de lentidão, em resolução horária e horizonte de uma hora, para o período de 2022 a 2024. Não foram consideradas previsões por trecho de via nem horizontes superiores a uma hora. Entre as limitações previstas, destacam-se a ausência de dados sobre obras e interdições programadas, a resolução horária das variáveis meteorológicas, que pode atenuar o efeito de chuvas intensas de curta duração, e a avaliação do

EXEMPLO DIDÁTICO: trabalho fictício, com dados simulados, elaborado para ilustrar o uso do modelo

painel, prevista apenas como protótipo, sem implantação em ambiente operacional.

EXEMPLO DIDÁTICO: trabalho fictício, com dados simulados, elaborado para ilustrar o uso do modelo

4 RESULTADOS PRELIMINARES

Resumo do capítulo

Este capítulo apresenta os resultados obtidos até o momento. A caracterização da base confirma a forte sazonalidade diária e semanal da lentidão. A prova de conceito, realizada com três dos cinco modelos previstos, indica que a floresta aleatória reduz o erro em cerca de 37% em relação à média histórica e supera o modelo SARIMA. Os resultados preliminares orientam as etapas seguintes, descritas no Capítulo 5.

4.1 Caracterização da base de dados

A Tabela 1 apresenta as estatísticas descritivas da extensão de lentidão por tipo de dia. Os dias úteis concentram valores médios quase três vezes superiores aos de fins de semana e feriados, além de maior dispersão, o que indica a predominância dos deslocamentos pendulares na formação dos congestionamentos.

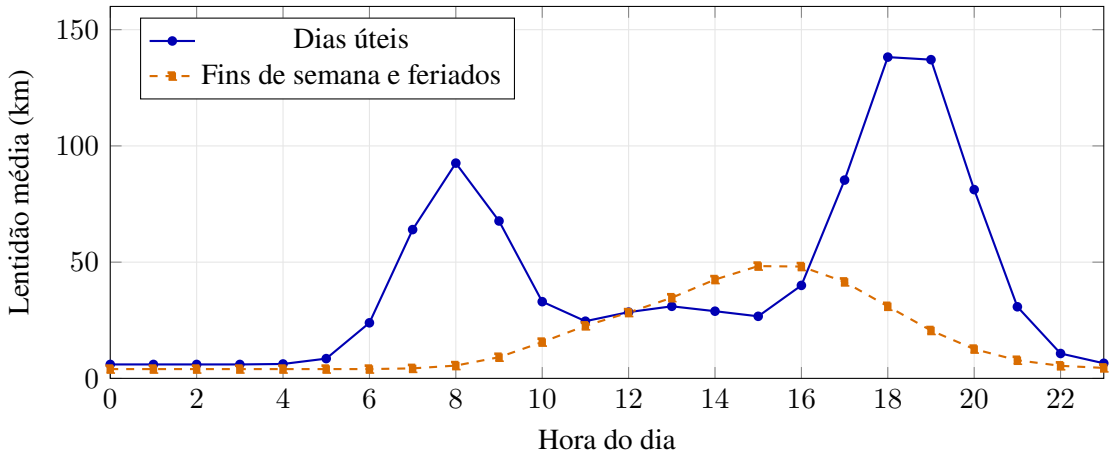
Tabela 1 – Estatísticas descritivas da extensão de lentidão (km), 2022 a 2024

Tipo de dia	Horas	Média	Desvio-padrão	Mínimo	Máximo
Dias úteis	18.072	52,4	45,1	0,0	187,3
Fins de semana e feriados	8.232	18,6	15,2	0,0	96,4
Total	26.304	41,8	41,2	0,0	187,3

Fonte: Elaborada pela autora (2026).

O perfil horário médio, representado na Figura 4, evidencia dois picos nos dias úteis, às 8h e entre 18h e 19h, sendo o vespertino mais intenso e prolongado. Nos fins de semana, a lentidão distribui-se de forma mais homogênea, com máximo no meio da tarde.

Figura 4 – Perfil horário médio da extensão de lentidão por tipo de dia



Fonte: Elaborada pela autora (2026).

4.2 Prova de conceito

Para verificar a viabilidade do protocolo de modelagem, realizou-se uma prova de conceito com três modelos: a média histórica, adotada como referência, o SARIMA e a floresta aleatória. Os modelos foram ajustados conforme o protocolo descrito na Seção 3.6.3 e avaliados na última partição de validação, correspondente ao segundo semestre de 2023. O conjunto de teste de 2024 foi preservado e só será utilizado na comparação final, após a definição de todos os modelos. A Tabela 2 apresenta os resultados.

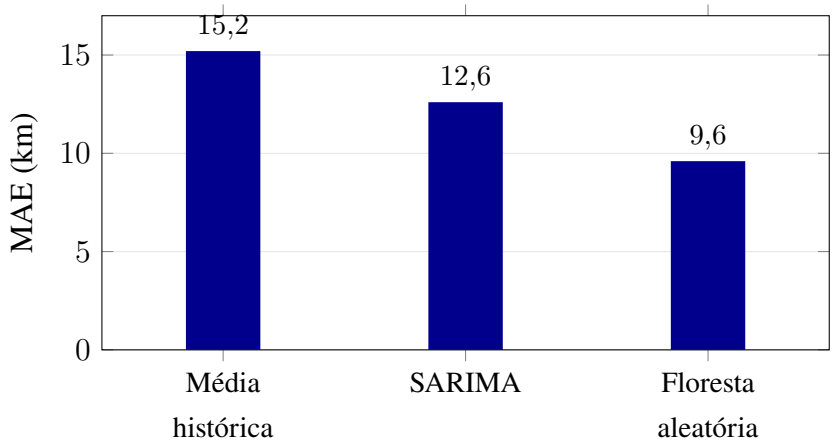
Tabela 2 – Desempenho preliminar dos modelos na última partição de validação (2º semestre de 2023)

Modelo	**MAE (km)**	**RMSE (km)**	R^2	**Ganho** G **(%)**
Média histórica (referência)	15,2	20,1	0,59	–
SARIMA	12,6	16,9	0,71	17,1
Floresta aleatória	**9,6**	**13,2**	**0,82**	**36,8**

Fonte: Elaborada pela autora (2026).

A Figura 5 compara o erro absoluto médio dos três modelos.

Figura 5 – Erro absoluto médio dos modelos avaliados na prova de conceito



Fonte: Elaborada pela autora (2026).

4.3 Discussão dos resultados preliminares

Os resultados preliminares confirmam a vantagem dos modelos baseados em árvores sobre os modelos sazonais clássicos, em linha com a evolução descrita por Vlahogianni; Karlaftis; Golias (2014). O ganho de 36,8% da floresta aleatória sugere que a incorporação de variáveis contextuais, como precipitação e ocorrências, acrescenta informação relevante à estrutura sazonal capturada pelo SARIMA. A literatura indica que modelos de *boosting* tendem a superar

as florestas aleatórias em dados tabulares (Chen; Guestrin, 2016), hipótese que será testada na próxima etapa.

Uma análise inicial dos resíduos da floresta aleatória mostrou erros mais elevados nos episódios de chuva intensa e nos dias com ocorrências múltiplas, o que reforça a importância da etapa de explicação: além de comparar modelos pelo erro médio, será necessário compreender em quais condições cada fator altera as previsões, o que será feito com valores SHAP, conforme a Seção 3.6.4.

EXEMPLO DIDÁTICO: trabalho fictício, com dados simulados, elaborado para ilustrar o uso do modelo

5 PLANOS PARA A CONTINUIDADE DO TRABALHO

Este capítulo apresenta as atividades necessárias para a conclusão da dissertação, a partir do estágio atual da pesquisa: revisão sistemática concluída, base de dados construída e prova de conceito realizada com três modelos.

5.1 Atividades previstas até a defesa

As atividades remanescentes, vinculadas aos objetivos específicos, são as seguintes:

1. **Incorporação das recomendações da banca de qualificação**, com revisão do texto e, se necessário, do protocolo de validação.
2. **Avaliação dos modelos de *boosting*** (*Gradient Boosting* e XGBoost), com ajuste de hiperparâmetros segundo a Equação (3.5) e comparação com os resultados da Tabela 2 (OE3).
3. **Análise por faixa horária e por tipo de dia**, para verificar a estabilidade do desempenho nos períodos de maior relevância operacional (OE3).
4. **Cálculo e análise das explicações SHAP** do modelo de melhor desempenho, em nível global e local (OE4).
5. **Desenvolvimento do protótipo de painel**, com a apresentação das previsões e da decomposição das contribuições (OE4).
6. **Redação dos capítulos de resultados e conclusão** e submissão de artigo científico com os principais achados.
7. **Disponibilização do código** em repositório aberto, com registro das versões das bibliotecas.

5.2 Cronograma

O Quadro 2 consolida as atividades descritas até a defesa da dissertação.

EXEMPLO DIDÁTICO: trabalho fictício, com dados simulados, elaborado para ilustrar o uso do modelo

Quadro 2 – Cronograma de atividades até a defesa

		2026					**2027**			
n	**ATIVIDADES**	**08**	**09**	**10**	**11**	**12**	**01**	**02**	**03**	**04**
1	Incorporação das recomendações da banca	■								
2	Avaliação dos modelos de *boosting*	■	■							
3	Análise por faixa horária e tipo de dia		■	■						
4	Cálculo e análise das explicações SHAP			■	■					
5	Desenvolvimento do protótipo de painel				■	■				
6	Redação dos resultados e da conclusão					■	■			
7	Submissão de artigo científico						■			
8	Disponibilização do código em repositório aberto							■		
9	**Defesa da dissertação**								■	
10	Versão final e depósito									■

Fonte: Elaborado pela autora (2026).

DECLARAÇÃO DE USO DE IA GENERATIVA

Esta declaração documenta o uso de ferramentas de inteligência artificial generativa na elaboração deste texto de qualificação. Para cada intervenção, reportam-se a *localização*, a *extensão* e a *verificação* realizada pela autora.

Ferramentas utilizadas

- **Modelo de linguagem de grande porte** (nome e versão registrados no repositório do projeto), acessado por interface de chat em plano institucional, com mecanismo de busca na web desativado e uso dos dados para treinamento desabilitado, em sessões conduzidas entre março e maio de 2026.

Intervenções e sua incidência sobre as afirmações

1. **Sugestões de concisão e clareza textual**. *Localização:* Capítulo 1. *Extensão:* reformulação sintática de frases preexistentes. *Verificação:* as sugestões foram aceitas apenas quando preservaram o sentido e o alcance das afirmações originais.

Delimitação da autoria e produção não mediada por IA

A formulação do problema, o desenho metodológico, a revisão sistemática, a construção da base de dados, a prova de conceito e todas as tabelas, quadros e figuras foram elaborados pela autora, sem uso de ferramentas de IA generativa. Nenhuma referência foi sugerida ou gerada por essas ferramentas.

REFERÊNCIAS

ARRIETA, A. B. *et al.* Explainable artificial intelligence (XAI): concepts, taxonomies, opportunities and challenges toward responsible AI. **Information Fusion**, v. 58, p. 82–115, 2020. DOI: https://doi.org/10.1016/j.inffus.2019.12.012.

BERGMEIR, C.; BENíTEZ, J. M. On the use of cross-validation for time series predictor evaluation. **Information Sciences**, v. 191, p. 192–213, 2012. DOI: https://doi.org/10.1016/j.ins.2011.12.028.

BREIMAN, L. Random forests. **Machine Learning**, v. 45, n. 1, p. 5–32, 2001. DOI: https://doi.org/10.1023/A:1010933404324.

CHEN, T.; GUESTRIN, C. XGBoost: a scalable tree boosting system. In: **Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining**. San Francisco: ACM, 2016. p. 785–794. DOI: https://doi.org/10.1145/2939672.2939785.

FRIEDMAN, J. H. Greedy function approximation: a gradient boosting machine. **The Annals of Statistics**, v. 29, n. 5, p. 1189–1232, 2001. DOI: https://doi.org/10.1214/aos/1013203451.

HEVNER, A. R. *et al.* Design science in information systems research. **MIS Quarterly**, v. 28, n. 1, p. 75–105, 2004. DOI: https://doi.org/10.2307/25148625.

HYNDMAN, R. J.; ATHANASOPOULOS, G. **Forecasting: principles and practice**. 3. ed. Melbourne: OTexts, 2021. Disponível em: https://otexts.com/fpp3/. Acesso em: 10 mar. 2026.

KITCHENHAM, B.; CHARTERS, S. **Guidelines for performing systematic literature reviews in software engineering**. Keele, 2007.

LUNDBERG, S. M. *et al.* From local explanations to global understanding with explainable AI for trees. **Nature Machine Intelligence**, v. 2, n. 1, p. 56–67, 2020. DOI: https://doi.org/10.1038/s42256-019-0138-9.

LUNDBERG, S. M.; LEE, S.-I. A unified approach to interpreting model predictions. In: **Advances in Neural Information Processing Systems 30**. Long Beach: Curran Associates, 2017. p. 4765–4774.

LV, Y. *et al.* Traffic flow prediction with big data: a deep learning approach. **IEEE Transactions on Intelligent Transportation Systems**, v. 16, n. 2, p. 865–873, 2015. DOI: https://doi.org/10.1109/TITS.2014.2345663.

MOLNAR, C. **Interpretable machine learning: a guide for making black box models explainable**. 2. ed. Munique: Christoph Molnar, 2022. Disponível em: https://christophm.github.io/interpretable-ml-book/. Acesso em: 10 mar. 2026.

PAGE, M. J. *et al.* The PRISMA 2020 statement: an updated guideline for reporting systematic reviews. **BMJ**, v. 372, p. n71, 2021. DOI: https://doi.org/10.1136/bmj.n71.

PEDREGOSA, F. *et al.* Scikit-learn: machine learning in Python. **Journal of Machine Learning Research**, v. 12, p. 2825–2830, 2011.

RIBEIRO, M. T.; SINGH, S.; GUESTRIN, C. "why should I trust you?": explaining the predictions of any classifier. In: **Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining**. San Francisco: ACM, 2016. p. 1135–1144. DOI: https://doi.org/10.1145/2939672.2939778.

RUSSELL, S.; NORVIG, P. **Artificial intelligence: a modern approach**. 4. ed. Hoboken: Pearson, 2021.

SHAPLEY, L. S. A value for n-person games. In: KUHN, H. W.; TUCKER, A. W. (Ed.). **Contributions to the theory of games: volume II**. Princeton: Princeton University Press, 1953, (Annals of Mathematics Studies, 28). p. 307–317.

VLAHOGIANNI, E. I.; KARLAFTIS, M. G.; GOLIAS, J. C. Short-term traffic forecasting: where we are and where we're going. **Transportation Research Part C: Emerging Technologies**, v. 43, p. 3–19, 2014. DOI: https://doi.org/10.1016/j.trc.2014.01.005.

WILLIAMS, B. M.; HOEL, L. A. Modeling and forecasting vehicular traffic flow as a seasonal ARIMA process: theoretical basis and empirical results. **Journal of Transportation Engineering**, v. 129, n. 6, p. 664–672, 2003. DOI: https://doi.org/10.1061/(ASCE)0733-947X(2003)129:6(664).

ZHANG, J. *et al.* Data-driven intelligent transportation systems: a survey. **IEEE Transactions on Intelligent Transportation Systems**, v. 12, n. 4, p. 1624–1639, 2011. DOI: https://doi.org/10.1109/TITS.2011.2158001.

EXEMPLO DIDÁTICO: trabalho fictício, com dados simulados, elaborado para ilustrar o uso do modelo

APÊNDICE A – Expressões de busca da revisão sistemática

Scopus

Quadro 3 – Expressão de busca aplicada na base Scopus

```
TITLE-ABS-KEY(
  ("traffic congestion" OR "traffic flow" OR "traffic speed")
  AND (forecast* OR predict*)
  AND ("machine learning" OR "gradient boosting" OR
       "random forest" OR "XGBoost" OR "deep learning")
  AND (explainab* OR interpretab* OR "SHAP")
)
AND PUBYEAR > 2014 AND PUBYEAR < 2026
AND LANGUAGE(English) AND DOCTYPE(ar)
```

Data da busca: 12/05/2025. Registros recuperados: 412.

Fonte: Elaborado pela autora (2026).

Web of Science

Quadro 4 – Expressão de busca aplicada na base Web of Science

```
TS=(
  ("traffic congestion" OR "traffic flow" OR "traffic speed")
  AND (forecast* OR predict*)
  AND ("machine learning" OR "gradient boosting" OR
       "random forest" OR "XGBoost" OR "deep learning")
  AND (explainab* OR interpretab* OR "SHAP")
)
```

Filtros: período (2015–2025), tipo (artigo), idioma (inglês). Data da busca: 12/05/2025. Registros recuperados: 287.

Fonte: Elaborado pela autora (2026).

APÊNDICE B – Dicionário de variáveis

O Quadro 5 descreve as variáveis da base de dados utilizada na modelagem.

Quadro 5 – Dicionário de variáveis da base horária

Variável	Tipo	Unidade	Descrição
`lentidao_km`	contínua	km	Extensão total de lentidão (alvo)
`lentidao_lag1`	contínua	km	Lentidão observada na hora anterior
`hora`	discreta	0 a 23	Hora do dia
`dia_semana`	categórica	1 a 7	Dia da semana
`feriado`	binária	0 ou 1	Indicador de feriado
`precipitacao`	contínua	mm	Precipitação acumulada na hora
`temperatura`	contínua	°C	Temperatura média do ar
`ocorrencias`	discreta	contagem	Ocorrências viárias ativas
`eventos`	binária	0 ou 1	Evento de grande porte na cidade

Fonte: Elaborado pela autora (2026).