UNIVERSIDADE NOVE DE JULHO – UNINOVE
PROGRAMA DE PÓS-GRADUAÇÃO EM INFORMÁTICA E GESTÃO DO CONHECIMENTO – PPGI

MARINA EXEMPLO DE OLIVEIRA

PREVISÃO EXPLICÁVEL DE CONGESTIONAMENTOS EM SÃO PAULO: UM SISTEMA INTELIGENTE DE APOIO À DECISÃO BASEADO EM APRENDIZADO DE MÁQUINA

São Paulo
2027

EXEMPLO DIDÁTICO: trabalho fictício, com dados simulados, elaborado para ilustrar o uso do modelo

MARINA EXEMPLO DE OLIVEIRA

PREVISÃO EXPLICÁVEL DE CONGESTIONAMENTOS EM SÃO PAULO: UM SISTEMA INTELIGENTE DE APOIO À DECISÃO BASEADO EM APRENDIZADO DE MÁQUINA

Dissertação apresentada ao Programa de Pós-Graduação em Informática e Gestão do Conhecimento (PPGI) da Universidade Nove de Julho (UNINOVE), como requisito parcial para a obtenção do grau de Mestra em Informática e Gestão do Conhecimento.

Orientador: Prof. Dr. Edson Melo de Souza

Data de ingresso: 03/2025
Linha de pesquisa: LP2 – Sistemas Inteligentes

São Paulo
2027

EXEMPLO DIDÁTICO: trabalho fictício, com dados simulados, elaborado para ilustrar o uso do modelo

Oliveira, Marina Exemplo de.
Previsão explicável de congestionamentos em São Paulo: um sistema inteligente de apoio à decisão baseado em aprendizado de máquina / Marina Exemplo de Oliveira. 2027.
46 f.

Dissertação (Mestrado) – Universidade Nove de Julho – UNINOVE, São Paulo, 2027.
Orientador: Prof. Dr. Edson Melo de Souza.

1. Sistemas inteligentes. 2. Previsão de tráfego. 3. Aprendizado de máquina. 4. Inteligência artificial explicável. I. Souza, Edson Melo de. II. Título.

CDU 004.8

FICHA FICTÍCIA, APENAS PARA ILUSTRAÇÃO. A ficha real é elaborada pela biblioteca.

Catalogação na Publicação (CIP)
Sistema de Bibliotecas Prof. José Storópoli

EXEMPLO DIDÁTICO: trabalho fictício, com dados simulados, elaborado para ilustrar o uso do modelo

MARINA EXEMPLO DE OLIVEIRA

PREVISÃO EXPLICÁVEL DE CONGESTIONAMENTOS EM SÃO PAULO: UM SISTEMA INTELIGENTE DE APOIO À DECISÃO BASEADO EM APRENDIZADO DE MÁQUINA

Dissertação apresentada ao Programa de Pós-Graduação em Informática e Gestão do Conhecimento (PPGI) da Universidade Nove de Julho (UNINOVE), como requisito parcial para a obtenção do grau de Mestra em Informática e Gestão do Conhecimento.

São Paulo, 15 de março de 2027

Prof. Dr. Edson Melo de Souza
Universidade Nove de Julho – Orientador

Prof. Dr. Nome Fictício Interno
Universidade Nove de Julho – Membro interno

Profa. Dra. Nome Fictícia Externa
Universidade Exemplo – Membro externo

EXEMPLO DIDÁTICO: trabalho fictício, com dados simulados, elaborado para ilustrar o uso do modelo

Aos meus pais, que me ensinaram o valor do estudo muito antes de eu compreendê-lo.

EXEMPLO DIDÁTICO: trabalho fictício, com dados simulados, elaborado para ilustrar o uso do modelo

AGRADECIMENTOS

Ao meu orientador, Prof. Dr. Edson Melo de Souza, pela orientação criteriosa, pela confiança e pelas contribuições decisivas ao desenvolvimento deste trabalho.

Aos professores membros da banca de qualificação, pelas recomendações que aprimoraram esta dissertação, em especial quanto ao protocolo de validação temporal dos modelos.

Aos docentes do Programa de Pós-Graduação em Informática e Gestão do Conhecimento, pelo conhecimento compartilhado nas disciplinas e seminários.

Aos colegas do grupo de pesquisa em Sistemas Inteligentes, pela troca de ideias e pelo apoio mútuo.

Agradeço à Universidade Nove de Julho (UNINOVE) pela concessão da bolsa de estudos do Fundo de Apoio à Pesquisa (FAP).

À minha família, pelo apoio incondicional e pela compreensão nos momentos de ausência.

Por fim, agradeço a todos que, direta ou indiretamente, contribuíram para a realização deste trabalho.

EXEMPLO DIDÁTICO: trabalho fictício, com dados simulados, elaborado para ilustrar o uso do modelo

"Essencialmente, todos os modelos estão errados, mas alguns são úteis."

(Box; Draper, 1987, p. 424, tradução nossa)

EXEMPLO DIDÁTICO: trabalho fictício, com dados simulados, elaborado para ilustrar o uso do modelo

RESUMO

Os congestionamentos urbanos impõem custos econômicos, ambientais e sociais às grandes metrópoles, e a cidade de São Paulo figura entre os casos mais emblemáticos no Brasil. Embora modelos de aprendizado de máquina apresentem bom desempenho na previsão de curto prazo das condições de tráfego, sua adoção por gestores públicos é limitada pela baixa transparência das previsões. Esta dissertação teve como objetivo desenvolver e avaliar um sistema inteligente de previsão explicável da extensão de lentidão viária em São Paulo, com horizonte de uma hora, capaz de apoiar decisões operacionais. A pesquisa, de natureza aplicada e abordagem quantitativa, adotou a *Design Science Research* como estratégia e foi conduzida em três etapas: revisão sistemática da literatura, segundo a recomendação PRISMA 2020, que resultou em 23 estudos analisados; construção de uma base horária integrando lentidão, condições meteorológicas, ocorrências viárias e calendário, no período de 2022 a 2024; e comparação de cinco modelos preditivos sob validação temporal com origem móvel. O modelo XGBoost obteve o melhor desempenho no conjunto de teste, com erro absoluto médio de 7,6 km e coeficiente de determinação de 0,88, o que representa redução de 48,6% no erro em relação à média histórica. A análise com valores SHAP indicou a hora do dia e a lentidão observada na hora anterior como os fatores de maior contribuição, seguidos do dia da semana e da precipitação, cujo efeito cresce de forma não linear com a intensidade da chuva. Os resultados foram incorporados a um protótipo de painel que apresenta, para cada previsão, a decomposição das contribuições de cada fator. Conclui-se que a combinação entre modelos de *boosting* e explicações baseadas em valores de Shapley oferece um equilíbrio adequado entre acurácia e transparência para o apoio à decisão na gestão do tráfego urbano.

Palavras-chave: sistemas inteligentes; previsão de tráfego; aprendizado de máquina; inteligência artificial explicável; mobilidade urbana.

EXEMPLO DIDÁTICO: trabalho fictício, com dados simulados, elaborado para ilustrar o uso do modelo

ABSTRACT

Urban congestion imposes economic, environmental and social costs on large metropolitan areas, and the city of São Paulo is among the most emblematic cases in Brazil. Although machine learning models perform well in short-term traffic forecasting, their adoption by public managers is limited by the low transparency of their predictions. This dissertation aimed to develop and evaluate an intelligent system for the explainable forecasting of traffic congestion length in São Paulo, with a one-hour horizon, capable of supporting operational decisions. The research, applied in nature and quantitative in approach, adopted Design Science Research as its strategy and was carried out in three stages: a systematic literature review, following the PRISMA 2020 statement, which resulted in 23 analysed studies; the construction of an hourly dataset integrating congestion, weather conditions, traffic incidents and calendar information from 2022 to 2024; and the comparison of five predictive models under rolling-origin temporal validation. The XGBoost model achieved the best performance on the test set, with a mean absolute error of 7.6 km and a coefficient of determination of 0.88, a 48.6% error reduction relative to the historical mean. The SHAP analysis identified the hour of the day and the congestion observed in the previous hour as the most influential factors, followed by the day of the week and precipitation, whose effect grows non-linearly with rainfall intensity. The results were incorporated into a dashboard prototype that presents, for each forecast, the decomposition of the contribution of each factor. The combination of boosting models and Shapley-value explanations offers an adequate balance between accuracy and transparency for decision support in urban traffic management.

Keywords: intelligent systems; traffic forecasting; machine learning; explainable artificial intelligence; urban mobility.

EXEMPLO DIDÁTICO: trabalho fictício, com dados simulados, elaborado para ilustrar o uso do modelo

LISTA DE FIGURAS

Figura 1 – Desenho da pesquisa e vínculo das etapas com os objetivos específicos . . 25
Figura 2 – Fluxograma do processo de seleção sistemática conforme a recomendação PRISMA 2020 26
Figura 3 – Representação esquemática dos corredores viários analisados 27
Figura 4 – Perfil horário médio da extensão de lentidão por tipo de dia 32
Figura 5 – Erro absoluto médio dos modelos no conjunto de teste 33
Figura 6 – Lentidão observada e prevista pelo XGBoost em uma semana do conjunto de teste 34
Figura 7 – Importância global das variáveis: média dos valores SHAP absolutos . . . 34
Figura 8 – Dependência entre a precipitação e o respectivo valor SHAP 35
Figura 9 – Protótipo do painel de previsão explicável 36

EXEMPLO DIDÁTICO: trabalho fictício, com dados simulados, elaborado para ilustrar o uso do modelo

LISTA DE QUADROS

Quadro 1 – Trabalhos de referência para a previsão explicável de tráfego 23

Quadro 2 – Decomposição da previsão para as 18h de uma quarta-feira chuvosa . . . 35

Quadro 3 – Expressão de busca aplicada na base Scopus 43
Quadro 4 – Expressão de busca aplicada na base Web of Science 43
Quadro 5 – Dicionário de variáveis da base horária 44

EXEMPLO DIDÁTICO: trabalho fictício, com dados simulados, elaborado para ilustrar o uso do modelo

LISTA DE TABELAS

Tabela 1 – Estatísticas descritivas da extensão de lentidão (km), 2022 a 2024 31
Tabela 2 – Desempenho dos modelos no conjunto de teste (2024) 32
Tabela 3 – Desempenho do XGBoost por faixa horária, dias úteis de 2024 33

EXEMPLO DIDÁTICO: trabalho fictício, com dados simulados, elaborado para ilustrar o uso do modelo

LISTA DE ABREVIATURAS E SIGLAS

CNS	Conselho Nacional de Saúde
GB	*Gradient Boosting*
IA	Inteligência Artificial
ITS	*Intelligent Transportation Systems* (Sistemas Inteligentes de Transporte)
LGPD	Lei Geral de Proteção de Dados Pessoais
LIME	*Local Interpretable Model-agnostic Explanations*
MAE	*Mean Absolute Error* (erro absoluto médio)
PRISMA	*Preferred Reporting Items for Systematic Reviews and Meta-Analyses*
RF	*Random Forest* (floresta aleatória)
RMSE	*Root Mean Squared Error* (raiz do erro quadrático médio)
SARIMA	*Seasonal AutoRegressive Integrated Moving Average*
SHAP	*SHapley Additive exPlanations*
XAI	*Explainable Artificial Intelligence* (Inteligência Artificial Explicável)

LISTA DE SÍMBOLOS

p, d, q	Ordens não sazonais do modelo SARIMA
P, D, Q	Ordens sazonais do modelo SARIMA
s	Período sazonal
ϕ_p, Φ_P	Polinômios autorregressivos não sazonal e sazonal
B	Operador de defasagem, $By_t = y_{t-1}$
y_t	Extensão total de lentidão observada na hora t (km)
θ_q, Θ_Q	Polinômios de médias móveis não sazonal e sazonal
ε_t	Termo de erro aleatório
t	Índice temporal (hora)
$\mathbf{x}$	Vetor de variáveis preditoras
T	Número de árvores da floresta aleatória
h_b	Árvore de decisão b
F_m	Modelo aditivo após a iteração m do *boosting*
ν	Taxa de aprendizado
j	Índice de uma variável preditora (jogador)
$\phi_j(v)$	Valor de Shapley da variável j
v	Função característica
S	Coalizão de variáveis que não contém j
N	Conjunto de variáveis preditoras
g	Modelo explicativo aditivo
ϕ_0	Valor de base (previsão média)
$\mathbf{z}'$	Vetor binário de presença das variáveis
$\hat{y}_t$	Extensão de lentidão prevista para a hora t (km)
n	Número de observações do conjunto avaliado
$\bar{y}$	Média das observações
λ	Vetor de hiperparâmetros
Λ	Espaço de busca dos hiperparâmetros
K	Número de partições da validação com origem móvel
r	Índice de uma partição de validação
G	Ganho relativo de desempenho (%)

EXEMPLO DIDÁTICO: trabalho fictício, com dados simulados, elaborado para ilustrar o uso do modelo

SUMÁRIO

1 INTRODUÇÃO 16
1.1 Contextualização 16
1.2 Problema de pesquisa 17
1.3 Objetivos 17
1.3.1 Objetivo geral 17
1.3.2 Objetivos específicos 17
1.4 Justificativa 18
1.5 Contribuições 18
1.6 Organização do trabalho 18

2 FUNDAMENTAÇÃO TEÓRICA 20
2.1 Sistemas inteligentes de transporte 20
2.2 Previsão de tráfego de curto prazo 20
2.3 Modelos baseados em conjuntos de árvores 21
2.4 Inteligência artificial explicável 22
2.5 Trabalhos relacionados 22

3 METODOLOGIA 24
3.1 Visão geral 24
3.2 Classificação da pesquisa 24
3.3 Desenho da pesquisa 24
3.4 Procedimentos de levantamento da literatura 25
3.5 Procedimentos de coleta de dados 26
3.6 Procedimentos de análise de dados 27
3.6.1 Modelos avaliados 27
3.6.2 Métricas de avaliação 28
3.6.3 Protocolo de validação 28
3.6.4 Explicação das previsões 29
3.7 Aspectos éticos 29
3.8 Delimitações e limitações do estudo 29

4 RESULTADOS E DISCUSSÃO 31
4.1 Caracterização da base de dados 31
4.2 Desempenho preditivo 32
4.3 Explicação das previsões 34
4.3.1 Explicação global 34
4.3.2 Explicação local 35
4.4 Protótipo de painel de apoio à decisão 35
4.5 Discussão 36

5 CONCLUSÃO 38
5.1 Resposta à pergunta de pesquisa 38
5.2 Contribuições teóricas e práticas 38
5.3 Limitações 38
5.4 Trabalhos futuros 39
DECLARAÇÃO DE USO DE IA GENERATIVA 40
REFERÊNCIAS 41
APÊNDICE A – Expressões de busca da revisão sistemática 43
APÊNDICE B – Dicionário de variáveis 44
APÊNDICE C – Trecho do código de modelagem 45
ANEXO A – Termo de autorização de uso de dados 46

1 INTRODUÇÃO

1.1 Contextualização

A mobilidade urbana constitui um dos desafios estruturais das grandes metrópoles. O crescimento da frota de veículos, a concentração de atividades econômicas em poucas regiões e a limitada capacidade de expansão da malha viária produzem congestionamentos recorrentes, com impactos sobre o tempo de deslocamento, o consumo de combustível, a emissão de poluentes e a qualidade de vida da população. Na cidade de São Paulo, o fenômeno assume escala particularmente expressiva, o que torna o tema objeto permanente da agenda pública e da pesquisa aplicada.

Nas últimas décadas, a disponibilidade de grandes volumes de dados de sensores, câmeras, dispositivos móveis e sistemas de monitoramento deu origem aos chamados Sistemas Inteligentes de Transporte (*Intelligent Transportation Systems*, ITS), que buscam transformar esses dados em informação útil para a operação e o planejamento do tráfego (Zhang *et al.*, 2011). Entre as funções desses sistemas, a previsão de curto prazo das condições de tráfego ocupa posição central, pois permite antecipar congestionamentos e acionar medidas preventivas, como a reprogramação semafórica, o reposicionamento de equipes de campo e a comunicação com os usuários (Vlahogianni; Karlaftis; Golias, 2014).

Os métodos de previsão evoluíram de modelos estatísticos de séries temporais, como os modelos autorregressivos integrados de médias móveis com componente sazonal (Williams; Hoel, 2003), para técnicas de aprendizado de máquina e aprendizado profundo, capazes de capturar relações não lineares entre múltiplas variáveis (Lv *et al.*, 2015). Esse ganho de capacidade preditiva, contudo, veio acompanhado de menor transparência. Modelos baseados em conjuntos de árvores ou em redes neurais produzem previsões precisas, mas não explicam, por si sós, *por que* determinado congestionamento é esperado. Para um gestor público, que precisa justificar decisões e alocar recursos escassos, essa opacidade representa uma barreira concreta à adoção (Arrieta *et al.*, 2020).

A Inteligência Artificial Explicável (*Explainable Artificial Intelligence*, XAI) surgiu como resposta a essa limitação, reunindo métodos que tornam inteligíveis as decisões de modelos complexos. Entre eles, destacam-se as explicações baseadas em valores de Shapley, que atribuem a cada variável preditora uma contribuição para a previsão individual, com fundamentação na teoria dos jogos cooperativos (Lundberg; Lee, 2017). Esta dissertação situa-se na interseção entre esses dois campos: a previsão de tráfego de curto prazo e a explicabilidade de modelos de aprendizado de máquina.

EXEMPLO DIDÁTICO: trabalho fictício, com dados simulados, elaborado para ilustrar o uso do modelo

1.2 Problema de pesquisa

A literatura sobre previsão de tráfego concentrou-se historicamente na acurácia dos modelos, e a explicabilidade das previsões permanece tratada de forma secundária (Vlahogianni; Karlaftis; Golias, 2014). Os estudos que incorporam métodos de XAI a esse domínio são recentes e, em sua maioria, avaliam a explicação como produto acessório, sem examinar de que modo ela pode ser apresentada ao gestor para apoiar decisões operacionais. Além disso, há poucos trabalhos dedicados ao contexto de metrópoles brasileiras, cujas dinâmicas de tráfego são fortemente influenciadas por fatores locais, como chuvas intensas de verão, calendário de feriados e eventos de grande porte.

Lacuna de Pesquisa. Faltam estudos que integrem previsão de curto prazo da lentidão viária e explicações locais das previsões em um sistema de apoio à decisão avaliado no contexto de uma metrópole brasileira.

Pergunta de Pesquisa. Em que medida um sistema inteligente baseado em aprendizado de máquina e valores de Shapley é capaz de prever com acurácia a extensão de lentidão viária em São Paulo, com horizonte de uma hora, e de explicar de forma inteligível os fatores que determinam cada previsão?

1.3 Objetivos

1.3.1 Objetivo geral

Desenvolver e avaliar um sistema inteligente de previsão explicável da extensão de lentidão viária na cidade de São Paulo, com horizonte de uma hora, voltado ao apoio à decisão na gestão do tráfego.

1.3.2 Objetivos específicos

1. Mapear, por meio de revisão sistemática da literatura, os métodos de previsão de tráfego de curto prazo e as abordagens de explicabilidade aplicadas a esse domínio.
2. Estruturar uma base de dados horária que integre lentidão viária, condições meteorológicas, ocorrências e calendário.
3. Comparar o desempenho de modelos estatísticos e de aprendizado de máquina na previsão da extensão de lentidão.
4. Explicar as previsões do modelo de melhor desempenho por meio de valores SHAP e incorporá-las a um protótipo de painel de apoio à decisão.

EXEMPLO DIDÁTICO: trabalho fictício, com dados simulados, elaborado para ilustrar o uso do modelo

1.4 Justificativa

Do ponto de vista teórico, o trabalho contribui para a aproximação entre duas linhas de pesquisa que evoluíram de forma relativamente independente: a previsão de tráfego e a explicabilidade de modelos. Do ponto de vista prático, a previsão antecipada da lentidão, acompanhada da indicação dos fatores que a determinam, permite que equipes de operação de tráfego atuem de modo preventivo e justifiquem tecnicamente suas decisões. No plano social, a redução de congestionamentos tem efeitos diretos sobre o tempo de deslocamento e a qualidade do ar, com benefícios distribuídos por toda a população urbana.

1.5 Contribuições

Este trabalho apresenta as seguintes contribuições:

- um panorama sistematizado da literatura sobre previsão explicável de tráfego, com a identificação de lacunas e tendências;
- um protocolo reprodutível de comparação de modelos sob validação temporal, adequado a séries com forte sazonalidade;
- evidências sobre o peso relativo de fatores temporais, meteorológicos e operacionais na formação da lentidão em São Paulo;
- um protótipo de painel que apresenta, para cada previsão, a decomposição das contribuições dos fatores, como referência para sistemas de apoio à decisão no setor público.

1.6 Organização do trabalho

Além desta Introdução, o trabalho está estruturado em quatro capítulos:

- Capítulo 2 (**Fundamentação teórica**). Apresenta os conceitos de sistemas inteligentes de transporte, os métodos de previsão de tráfego, os modelos baseados em árvores e as técnicas de explicabilidade, além dos trabalhos relacionados.
- Capítulo 3 (**Metodologia**). Descreve a classificação e o desenho da pesquisa, o protocolo da revisão sistemática, a construção da base de dados, os modelos avaliados e os critérios de validação.
- Capítulo 4 (**Resultados e discussão**). Apresenta o desempenho dos modelos, as explicações das previsões e o protótipo de painel, discutindo os achados à luz da literatura.
- Capítulo 5 (**Conclusão**). Responde à pergunta de pesquisa, sintetiza as contribuições e apresenta as limitações e os trabalhos futuros.

EXEMPLO DIDÁTICO: trabalho fictício, com dados simulados, elaborado para ilustrar o uso do modelo

Complementam o texto a Declaração de Uso de IA Generativa, as Referências, os Apêndices A a C e o Anexo A.

EXEMPLO DIDÁTICO: trabalho fictício, com dados simulados, elaborado para ilustrar o uso do modelo

2 FUNDAMENTAÇÃO TEÓRICA

Resumo do capítulo

Este capítulo apresenta os fundamentos que sustentam a pesquisa. Inicia-se pelos sistemas inteligentes de transporte e pela previsão de tráfego de curto prazo, com destaque para os modelos sazonais de séries temporais. Em seguida, são apresentados os modelos de aprendizado de máquina baseados em conjuntos de árvores e os métodos de inteligência artificial explicável, em particular os valores de Shapley e o método SHAP. O capítulo encerra-se com a análise dos trabalhos relacionados e com a delimitação da lacuna que orienta a investigação.

A fundamentação teórica organiza-se em quatro eixos, que acompanham a sequência dos objetivos específicos: sistemas inteligentes de transporte, previsão de tráfego, modelos baseados em árvores e explicabilidade. As fontes discutidas foram recuperadas segundo o protocolo descrito na Seção 3.4.

2.1 Sistemas inteligentes de transporte

Um sistema inteligente pode ser compreendido como um agente que percebe seu ambiente e age de modo a maximizar o alcance de seus objetivos (Russell; Norvig, 2021). No domínio da mobilidade, os ITS aplicam essa concepção à rede viária: coletam dados sobre o estado do tráfego, processam-nos por meio de modelos analíticos e apoiam, ou executam, ações de controle e informação. Zhang *et al.* (2011) caracterizam a transição para os ITS orientados por dados, nos quais a disponibilidade massiva de registros de sensores, veículos e dispositivos móveis desloca o foco dos modelos físicos de fluxo para modelos aprendidos a partir dos dados.

Nesta pesquisa, adota-se o entendimento de sistema inteligente como um artefato computacional que integra dados heterogêneos, produz previsões e as comunica ao decisor humano de forma inteligível. Essa delimitação é relevante porque desloca a avaliação do sistema da acurácia isolada para a utilidade da informação no processo decisório.

2.2 Previsão de tráfego de curto prazo

A previsão de tráfego de curto prazo refere-se à estimativa das condições da via, como fluxo, velocidade ou extensão de congestionamento, em horizontes que variam de poucos minutos a algumas horas. Em revisão abrangente, Vlahogianni; Karlaftis; Golias (2014) observam que o campo amadureceu na direção de modelos orientados por dados, mas apontam desafios persistentes, como a incorporação de fatores contextuais e a avaliação dos modelos em condições operacionais reais.

Entre os modelos estatísticos, destacam-se os modelos SARIMA, que representam a série como combinação de componentes autorregressivos, de médias móveis e sazonais. Williams; Hoel (2003) fundamentaram teoricamente o uso desses modelos para o fluxo veicular,

EXEMPLO DIDÁTICO: trabalho fictício, com dados simulados, elaborado para ilustrar o uso do modelo

cuja periodicidade diária e semanal se ajusta à estrutura sazonal. Na notação de Hyndman; Athanasopoulos (2021), um modelo SARIMA$(p,d,q)(P,D,Q)_s$ é expresso pela Equação (2.1):

$$\phi_p(B)\,\Phi_P(B^s)\,(1-B)^d\,(1-B^s)^D\,y_t = \theta_q(B)\,\Theta_Q(B^s)\,\varepsilon_t, \tag{2.1}$$

em que y_t é o valor da série no instante t, B é o operador de defasagem ($By_t = y_{t-1}$), s é o período sazonal, ϕ_p e Φ_P são os polinômios autorregressivos não sazonal e sazonal, θ_q e Θ_Q são os polinômios de médias móveis correspondentes, d e D são as ordens de diferenciação e ε_t é o termo de erro aleatório.

Os modelos de aprendizado profundo ampliaram a capacidade de capturar padrões complexos. Lv *et al.* (2015) demonstraram que autocodificadores empilhados superam modelos tradicionais na previsão do fluxo em grandes volumes de dados. Esses modelos, entretanto, exigem grandes bases de treinamento e oferecem pouca transparência, o que motiva o interesse por alternativas baseadas em árvores, que combinam bom desempenho em dados tabulares com maior facilidade de explicação.

2.3 Modelos baseados em conjuntos de árvores

As florestas aleatórias (*Random Forest*, RF) combinam múltiplas árvores de decisão treinadas sobre amostras *bootstrap* dos dados e subconjuntos aleatórios das variáveis (Breiman, 2001). Para problemas de regressão, a previsão da floresta corresponde à média das previsões das árvores individuais, conforme a Equação (2.2):

$$\hat{f}_{\mathrm{RF}}(\mathbf{x}) = \frac{1}{T}\sum_{b=1}^{T} h_b(\mathbf{x}), \tag{2.2}$$

em que $\mathbf{x}$ é o vetor de variáveis preditoras, T é o número de árvores e h_b é a b-ésima árvore.

O *boosting* por gradiente (*Gradient Boosting*, GB), por sua vez, constrói o modelo de forma sequencial, adicionando a cada iteração uma árvore ajustada aos resíduos do modelo anterior (Friedman, 2001). A atualização é dada pela Equação (2.3):

$$F_m(\mathbf{x}) = F_{m-1}(\mathbf{x}) + \nu\, h_m(\mathbf{x}), \tag{2.3}$$

em que F_m é o modelo após a iteração m, h_m é a árvore ajustada ao gradiente negativo da função de perda e $\nu \in (0,1]$ é a taxa de aprendizado. O XGBoost aperfeiçoa essa formulação com regularização explícita da complexidade das árvores e otimizações de desempenho computacional, o que o tornou referência em problemas de dados tabulares (Chen; Guestrin, 2016).

EXEMPLO DIDÁTICO: trabalho fictício, com dados simulados, elaborado para ilustrar o uso do modelo

2.4 Inteligência artificial explicável

Arrieta *et al.* (2020) definem a XAI como o conjunto de técnicas que produzem modelos ou explicações compreensíveis para uma audiência específica, e distinguem os modelos transparentes por concepção das técnicas aplicadas posteriormente a modelos complexos. Entre estas últimas, o LIME (*Local Interpretable Model-agnostic Explanations*) aproxima o comportamento do modelo na vizinhança de uma previsão por um modelo linear simples (Ribeiro; Singh; Guestrin, 2016). Essa aproximação local, embora intuitiva, pode variar conforme o procedimento de amostragem, o que compromete a estabilidade das explicações (Molnar, 2022).

Uma alternativa com garantias teóricas decorre da teoria dos jogos cooperativos. Shapley (1953) propôs um critério de repartição do ganho de uma coalizão entre seus participantes, segundo o qual a contribuição do jogador j corresponde à média ponderada de suas contribuições marginais a todas as coalizões possíveis, conforme a Equação (2.4):

$$\phi_j(v) = \sum_{S \subseteq N \setminus \{j\}} \frac{|S|!\ (|N| - |S| - 1)!}{|N|!} \Big[v\left(S \cup \{j\}\right) - v(S) \Big], \tag{2.4}$$

em que N é o conjunto de jogadores, S é uma coalizão que não contém j e v é a função característica, que associa a cada coalizão o ganho por ela obtido.

Lundberg; Lee (2017) transpuseram essa formulação para a explicação de modelos preditivos, tratando as variáveis como jogadores e a previsão como o ganho a ser repartido. O método resultante, denominado SHAP (*SHapley Additive exPlanations*), expressa cada previsão como a soma de um valor de base e das contribuições das variáveis, conforme a Equação (2.5):

$$g(\mathbf{z}') = \phi_0 + \sum_{j \in N} \phi_j \, z'_j, \tag{2.5}$$

em que g é o modelo explicativo, ϕ_0 é o valor de base, correspondente à previsão média, e $z'_j \in \{0, 1\}$ indica a presença da variável j. Essa propriedade aditiva permite apresentar ao decisor, de forma direta, quanto cada fator elevou ou reduziu a previsão. Para modelos baseados em árvores, Lundberg *et al.* (2020) desenvolveram o algoritmo TreeSHAP, que calcula os valores exatos em tempo polinomial e viabiliza a explicação de grandes volumes de previsões.

2.5 Trabalhos relacionados

A revisão sistemática descrita na Seção 3.4 resultou em 23 estudos analisados. O Quadro 1 apresenta os trabalhos de maior influência sobre as escolhas desta pesquisa, comparados segundo o foco metodológico e a principal contribuição.

EXEMPLO DIDÁTICO: trabalho fictício, com dados simulados, elaborado para ilustrar o uso do modelo

Quadro 1 – Trabalhos de referência para a previsão explicável de tráfego

ID	Referência	Foco metodológico	Principal contribuição
E01	Williams; Hoel (2003)	Modelagem SARIMA do fluxo veicular.	Fundamentação teórica da sazonalidade do tráfego em modelos de séries temporais.
E02	Zhang *et al.* (2011)	Revisão sobre ITS orientados por dados.	Caracterização da transição para sistemas baseados em dados massivos.
E03	Vlahogianni; Karlaftis; Golias (2014)	Revisão sobre previsão de curto prazo.	Agenda de pesquisa com ênfase em contexto e avaliação operacional.
E04	Lv *et al.* (2015)	Aprendizado profundo com autocodificadores empilhados.	Ganho de acurácia em grandes volumes de dados de fluxo.
E05	Chen; Guestrin (2016)	*Boosting* por gradiente regularizado.	Algoritmo escalável e de alto desempenho em dados tabulares.
E06	Lundberg *et al.* (2020)	Explicações SHAP exatas para árvores.	Algoritmo TreeSHAP e explicações locais e globais consistentes.

Fonte: Elaborado pela autora (2027).

A comparação evidencia dois movimentos paralelos. De um lado, a previsão de tráfego avançou em acurácia, dos modelos sazonais (E01) ao aprendizado profundo (E04). De outro, os métodos de explicação ganharam fundamentação teórica e eficiência computacional (E06). Os estudos que combinam ambos os movimentos, entre os 23 analisados, tratam a explicação como resultado complementar e não a integram a um artefato voltado ao decisor. Essa constatação reforça a lacuna anunciada na Seção 1.2 e justifica a proposta de um sistema que articule previsão, explicação e apresentação ao gestor.

EXEMPLO DIDÁTICO: trabalho fictício, com dados simulados, elaborado para ilustrar o uso do modelo

3 METODOLOGIA

Resumo do capítulo

Este capítulo descreve os procedimentos adotados para responder à pergunta de pesquisa. A investigação, de natureza aplicada e abordagem quantitativa, segue a estratégia da Design Science Research e organiza-se em quatro etapas: revisão sistemática da literatura, construção da base de dados, modelagem e avaliação preditiva, e explicação das previsões com desenvolvimento do artefato. São detalhados as fontes de dados, as variáveis, os modelos comparados, as métricas de avaliação, o protocolo de validação temporal e os aspectos éticos.

3.1 Visão geral

A pesquisa foi conduzida de modo a vincular cada etapa a um objetivo específico. A revisão da literatura orientou a escolha dos modelos e das variáveis; a construção da base forneceu os dados para treinamento e teste; a modelagem identificou o modelo de melhor desempenho; e a etapa de explicação transformou as previsões em informação utilizável pelo decisor. As seções seguintes detalham cada uma dessas etapas.

3.2 Classificação da pesquisa

Quanto à natureza, a pesquisa é aplicada, pois busca gerar conhecimento voltado à solução de um problema concreto da gestão do tráfego. Quanto à abordagem, é quantitativa, uma vez que os modelos são avaliados por métricas numéricas de erro. Quanto aos objetivos, é explicativa, ao investigar os fatores que determinam a lentidão viária. Quanto aos procedimentos, combina pesquisa bibliográfica, na forma de revisão sistemática, e experimentação computacional.

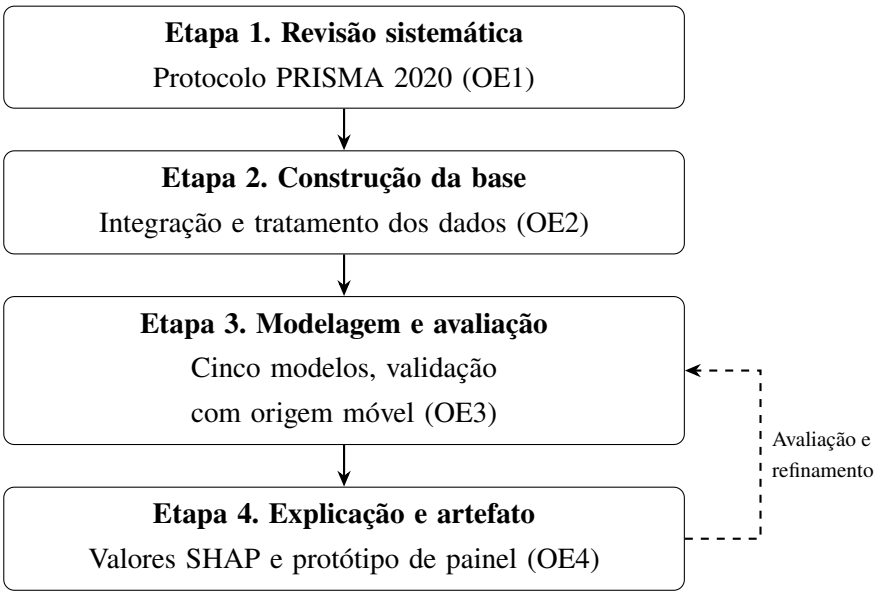
A estratégia geral adotada é a *Design Science Research*, que orienta a construção e a avaliação de artefatos destinados a resolver problemas relevantes, com rigor na fundamentação e na avaliação (Hevner *et al.*, 2004). O artefato desta pesquisa é o sistema de previsão explicável, composto pelo modelo preditivo, pelo módulo de explicação e pelo protótipo de painel.

3.3 Desenho da pesquisa

A Figura 1 apresenta as quatro etapas da pesquisa e sua correspondência com os objetivos específicos (OE). A seta tracejada indica o ciclo de avaliação e refinamento característico da *Design Science Research*, no qual os resultados da explicação retroalimentam a seleção de variáveis e a configuração dos modelos.

EXEMPLO DIDÁTICO: trabalho fictício, com dados simulados, elaborado para ilustrar o uso do modelo

Figura 1 – Desenho da pesquisa e vínculo das etapas com os objetivos específicos



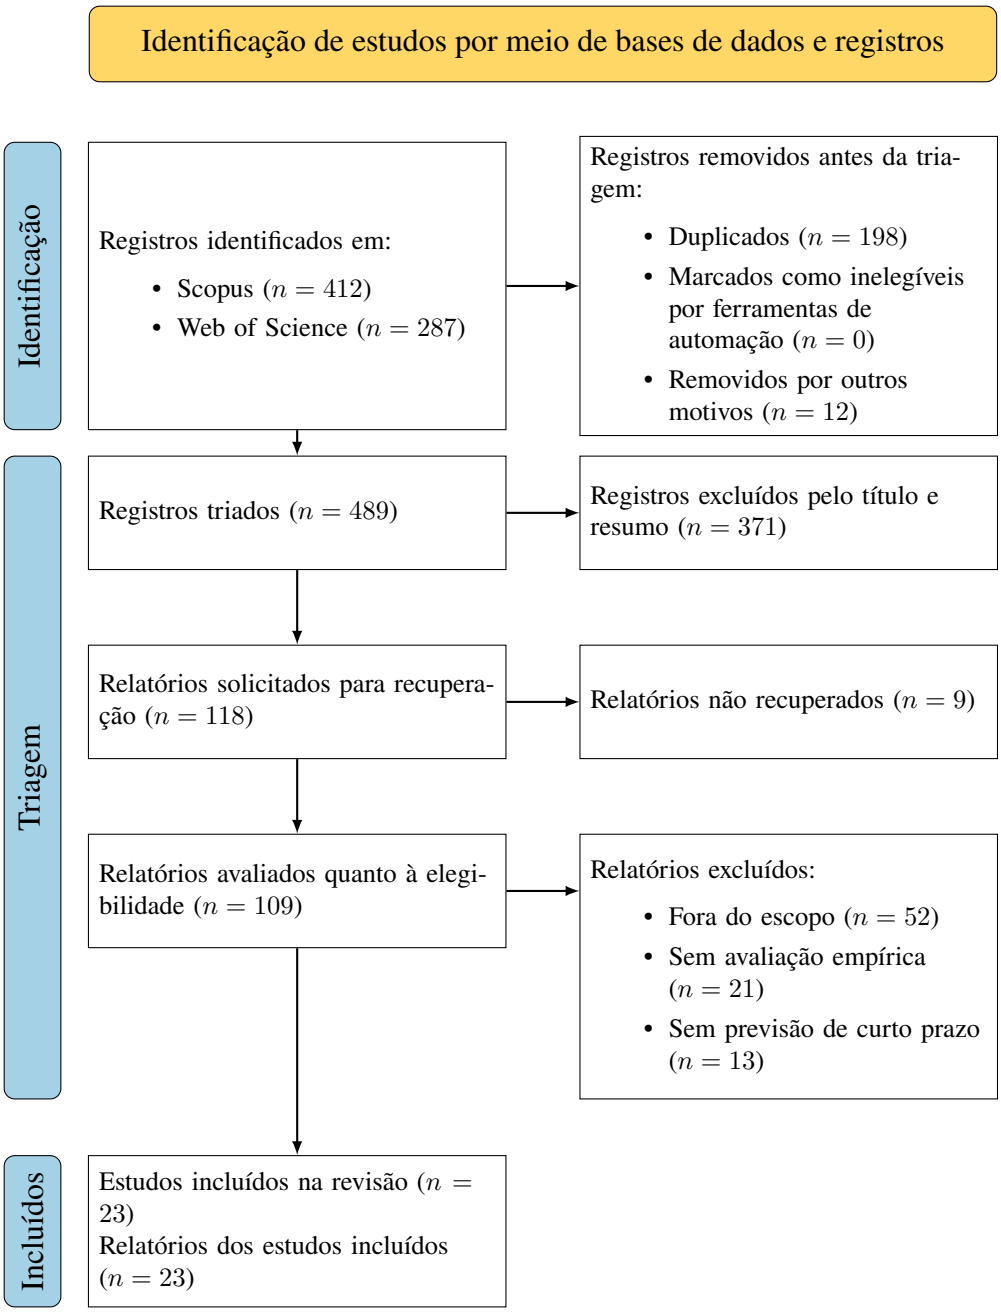
Fonte: Elaborada pela autora (2027).

3.4 Procedimentos de levantamento da literatura

A revisão sistemática seguiu as diretrizes de Kitchenham; Charters (2007) para a condução e a recomendação PRISMA 2020 para o relato (Page *et al.*, 2021). As buscas foram realizadas nas bases Scopus e Web of Science, em maio de 2025, com expressões que combinam termos de tráfego, previsão, aprendizado de máquina e explicabilidade, apresentadas integralmente no Apêndice A. Foram incluídos artigos publicados entre 2015 e 2025, em inglês, com avaliação empírica de modelos de previsão de curto prazo. O fluxo de seleção está representado na Figura 2.

EXEMPLO DIDÁTICO: trabalho fictício, com dados simulados, elaborado para ilustrar o uso do modelo

Figura 2 – Fluxograma do processo de seleção sistemática conforme a recomendação PRISMA 2020



Fonte: Elaborada pela autora (2027).

3.5 Procedimentos de coleta de dados

A base de dados integra quatro fontes, organizadas em resolução horária para o período de 1º de janeiro de 2022 a 31 de dezembro de 2024, o que totaliza 26.304 observações[1]:

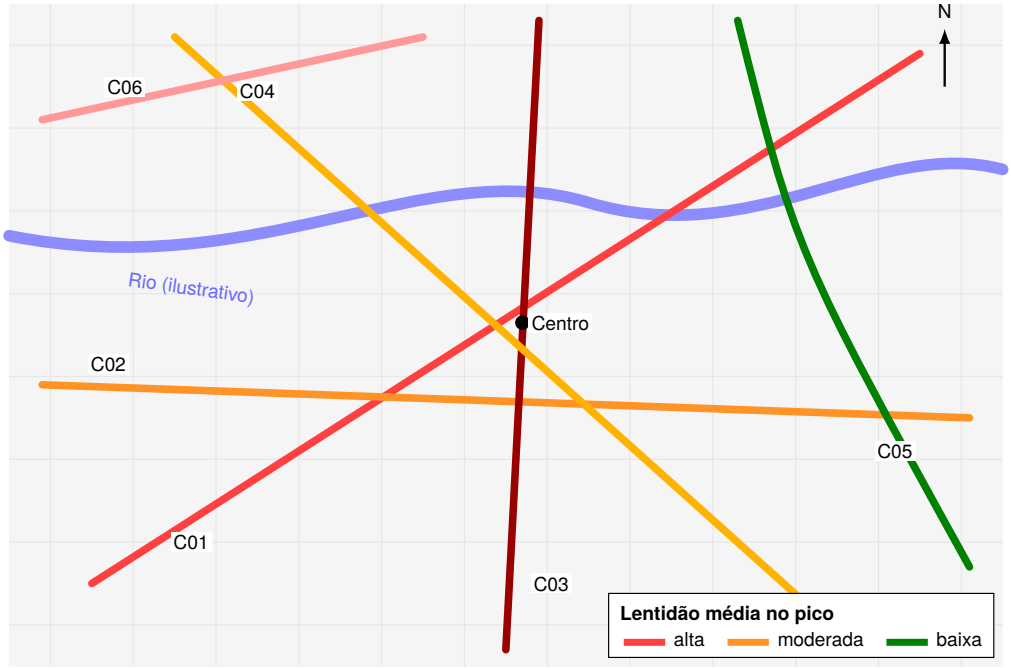
1. **Lentidão viária**: extensão total de lentidão monitorada nos corredores da cidade, em quilômetros, variável a ser prevista;

[1] Todos os dados deste trabalho são simulados. A base foi gerada para fins didáticos e reproduz apenas a estrutura de dados que um estudo real sobre o tema utilizaria.

2. **Condições meteorológicas**: precipitação horária (mm) e temperatura do ar (°C);
3. **Ocorrências**: número de ocorrências viárias ativas, como acidentes e veículos quebrados;
4. **Calendário**: hora do dia, dia da semana, feriados e eventos de grande porte.

A Figura 3 ilustra, de forma esquemática, os seis corredores considerados na análise por corredor, utilizada na etapa exploratória.

Figura 3 – Representação esquemática dos corredores viários analisados



Fonte: Elaborada pela autora (2027).

O tratamento dos dados compreendeu a remoção de registros inconsistentes, a imputação de valores ausentes (1,8% das observações) por interpolação linear restrita a lacunas de até três horas e a construção da variável de defasagem, que corresponde à lentidão observada na hora anterior. O dicionário completo das variáveis encontra-se no Apêndice B.

3.6 Procedimentos de análise de dados

3.6.1 Modelos avaliados

Foram comparados cinco modelos de complexidade crescente: (i) a média histórica para a mesma hora e o mesmo tipo de dia, adotada como referência; (ii) o modelo SARIMA, definido na Equação (2.1); (iii) a floresta aleatória, definida na Equação (2.2); (iv) o *boosting* por gradiente, definido na Equação (2.3); e (v) o XGBoost (Chen; Guestrin, 2016). Os modelos foram implementados em Python, com as bibliotecas *statsmodels*, *scikit-learn* (Pedregosa *et*

al., 2011), *xgboost* e *shap*, executadas em ambiente com versões registradas no repositório do projeto.

3.6.2 Métricas de avaliação

O desempenho foi avaliado no conjunto de teste por três métricas complementares. O erro absoluto médio (*Mean Absolute Error*, MAE), expresso na mesma unidade da variável prevista, é dado pela Equação (3.1):

$$\mathrm{MAE} = \frac{1}{n}\sum_{t=1}^{n} \left| y_t - \hat{y}_t \right|, \tag{3.1}$$

em que $\hat{y}_t$ é a extensão de lentidão prevista para a hora t e n é o número de observações avaliadas. A raiz do erro quadrático médio (*Root Mean Squared Error*, RMSE), que penaliza com mais intensidade os erros elevados, e o coeficiente de determinação (R^2) são calculados conforme as Equações (3.2) e (3.3):

$$\mathrm{RMSE} = \sqrt{\frac{1}{n}\sum_{t=1}^{n} \left(y_t - \hat{y}_t \right)^2}, \tag{3.2}$$

$$R^2 = 1 - \frac{\sum_{t=1}^{n} \left(y_t - \hat{y}_t \right)^2}{\sum_{t=1}^{n} \left(y_t - \bar{y} \right)^2}, \tag{3.3}$$

em que $\bar{y}$ é a média das observações. Para facilitar a comparação com a referência, calculou-se ainda o ganho relativo G, definido na Equação (3.4):

$$G = \frac{\mathrm{MAE}_{\text{ref}} - \mathrm{MAE}_{\text{modelo}}}{\mathrm{MAE}_{\text{ref}}} \times 100\%. \tag{3.4}$$

3.6.3 Protocolo de validação

Como a variável prevista é uma série temporal, a validação cruzada convencional, que embaralha as observações, produziria estimativas otimistas ao permitir que o modelo aprendesse com dados futuros. Adotou-se, por isso, a validação com origem móvel recomendada por Bergmeir; Benítez (2012). Os dados de 2022 e 2023 (17.520 horas) foram reservados para treinamento e ajuste, e os de 2024 (8.784 horas) para o teste final, utilizado uma única vez. O ajuste dos hiperparâmetros λ de cada modelo seguiu a Equação (3.5):

$$\hat{\lambda} = \arg\min_{\lambda \in \Lambda} \; \frac{1}{K}\sum_{r=1}^{K} \mathrm{MAE}_r(\lambda), \tag{3.5}$$

onde Λ é o espaço de busca, $K = 6$ é o número de partições e MAE_r é o erro na r-ésima partição de validação. O procedimento está descrito no Algoritmo 1.

Algoritmo 1: Validação com origem móvel para ajuste de hiperparâmetros

Entrada: série de treinamento $\{(\mathbf{x}_t, y_t)\}$; espaço de busca Λ; número de partições K
Saída: hiperparâmetros selecionados $\hat{\lambda}$

para cada $\lambda \in \Lambda$ **faça**
  para $r \leftarrow 1$ **até** K **faça**
    definir o período de treino até a origem r e o período de validação seguinte;
    ajustar o modelo com λ no período de treino;
    calcular $\mathrm{MAE}_r(\lambda)$ no período de validação;
  calcular a média dos K erros;
retorna λ com menor erro médio;

3.6.4 Explicação das previsões

A contribuição de cada variável para as previsões do modelo de melhor desempenho foi estimada pelos valores de Shapley, definidos na Equação (2.4), na forma aditiva da Equação (2.5). Como o cálculo exato exige avaliar $2^{|N|-1}$ coalizões para cada variável, adotou-se o algoritmo TreeSHAP (Lundberg *et al.*, 2020), que obtém os valores exatos em tempo polinomial para modelos baseados em árvores. As explicações foram analisadas em dois níveis: global, pela média dos valores absolutos de cada variável, e local, pela decomposição de previsões individuais apresentada no painel.

3.7 Aspectos éticos

A pesquisa utiliza exclusivamente dados agregados de tráfego, meteorologia e calendário, sem qualquer informação que identifique pessoas. Por não envolver seres humanos, direta ou indiretamente, não se enquadra nas hipóteses de submissão ao sistema de Comitês de Ética em Pesquisa previstas nas Resoluções do Conselho Nacional de Saúde (CNS) n.º 466/2012 e n.º 510/2016, nem envolve tratamento de dados pessoais nos termos da Lei Geral de Proteção de Dados Pessoais (LGPD). O uso dos dados observou os termos da autorização reproduzida no Anexo A.

3.8 Delimitações e limitações do estudo

O estudo delimita-se à previsão da extensão total de lentidão, em resolução horária e horizonte de uma hora, para o período de 2022 a 2024. Não foram consideradas previsões por trecho de via nem horizontes superiores a uma hora. Entre as limitações previstas, destacam-se a ausência de dados sobre obras e interdições programadas, a resolução horária das variáveis meteorológicas, que pode atenuar o efeito de chuvas intensas de curta duração, e a avaliação do

EXEMPLO DIDÁTICO: trabalho fictício, com dados simulados, elaborado para ilustrar o uso do modelo

painel restrita a um protótipo, sem implantação em ambiente operacional.

EXEMPLO DIDÁTICO: trabalho fictício, com dados simulados, elaborado para ilustrar o uso do modelo

4 RESULTADOS E DISCUSSÃO

Resumo do capítulo

Este capítulo apresenta e discute os resultados. A análise exploratória confirma a forte sazonalidade diária e semanal da lentidão. Na comparação preditiva, o XGBoost obteve o menor erro, com redução de 48,6% em relação à média histórica, e manteve desempenho superior em todas as faixas horárias. A análise com valores SHAP identifica a hora do dia e a lentidão da hora anterior como fatores dominantes e revela efeito não linear da precipitação. Por fim, apresenta-se o protótipo de painel que incorpora as explicações locais.

4.1 Caracterização da base de dados

A Tabela 1 apresenta as estatísticas descritivas da extensão de lentidão por tipo de dia. Os dias úteis concentram valores médios quase três vezes superiores aos de fins de semana e feriados, além de maior dispersão, o que indica a predominância dos deslocamentos pendulares na formação dos congestionamentos.

Tabela 1 – Estatísticas descritivas da extensão de lentidão (km), 2022 a 2024

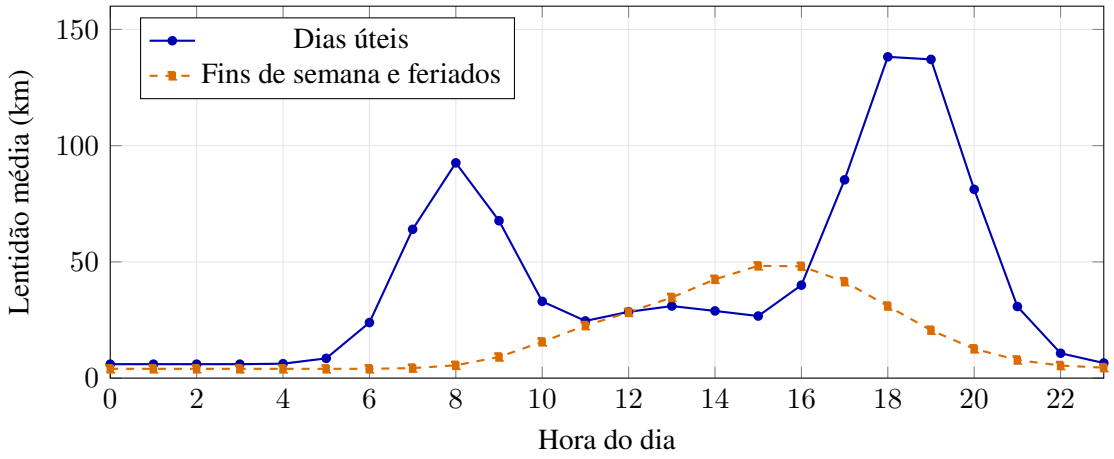
Tipo de dia	Horas	Média	Desvio-padrão	Mínimo	Máximo
Dias úteis	18.072	52,4	45,1	0,0	187,3
Fins de semana e feriados	8.232	18,6	15,2	0,0	96,4
Total	26.304	41,8	41,2	0,0	187,3

Fonte: Elaborada pela autora (2027).

O perfil horário médio, representado na Figura 4, evidencia dois picos nos dias úteis, às 8h e entre 18h e 19h, sendo o vespertino mais intenso e prolongado. Nos fins de semana, a lentidão distribui-se de forma mais homogênea, com máximo no meio da tarde.

EXEMPLO DIDÁTICO: trabalho fictício, com dados simulados, elaborado para ilustrar o uso do modelo

Figura 4 – Perfil horário médio da extensão de lentidão por tipo de dia



Fonte: Elaborada pela autora (2027).

4.2 Desempenho preditivo

A Tabela 2 resume o desempenho dos cinco modelos no conjunto de teste, com as métricas definidas nas Equações (3.1) a (3.4). Todos os modelos superaram a referência, mas a diferença entre os modelos estatísticos e os baseados em árvores é expressiva: o SARIMA reduziu o erro em 18,2%, ao passo que os três modelos de árvores alcançaram reduções entre 39,9% e 48,6%.

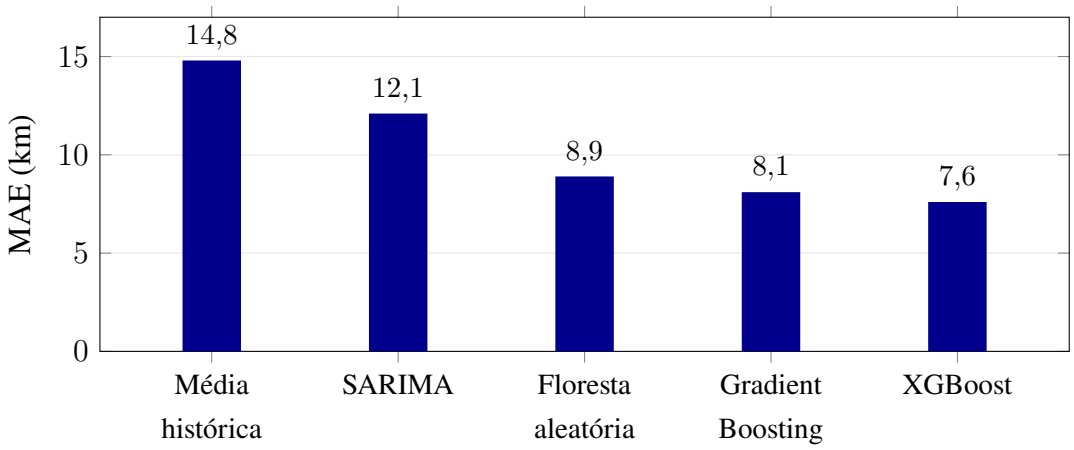
Tabela 2 – Desempenho dos modelos no conjunto de teste (2024)

Modelo	**MAE (km)**	**RMSE (km)**	R^2	**Ganho** G **(%)**
Média histórica (referência)	14,8	19,6	0,61	–
SARIMA	12,1	16,3	0,73	18,2
Floresta aleatória	8,9	12,4	0,84	39,9
Gradient Boosting	8,1	11,5	0,86	45,3
XGBoost	**7,6**	**10,9**	**0,88**	**48,6**

Fonte: Elaborada pela autora (2027).

A Figura 5 apresenta o erro absoluto médio de cada modelo, o que permite visualizar a magnitude da diferença entre as abordagens.

Figura 5 – Erro absoluto médio dos modelos no conjunto de teste



Fonte: Elaborada pela autora (2027).

O desempenho do XGBoost foi examinado por faixa horária, uma vez que erros nos períodos de pico têm maior relevância operacional. Conforme a Tabela 3, o erro absoluto cresce nos picos, acompanhando a maior variabilidade da lentidão, mas o erro relativo à média de cada faixa é justamente o menor nesses períodos, entre 14% e 18%. Nas faixas de baixa lentidão, como a madrugada, o erro relativo é elevado, mas de pouca consequência operacional, pois corresponde a poucos quilômetros.

Tabela 3 – Desempenho do XGBoost por faixa horária, dias úteis de 2024

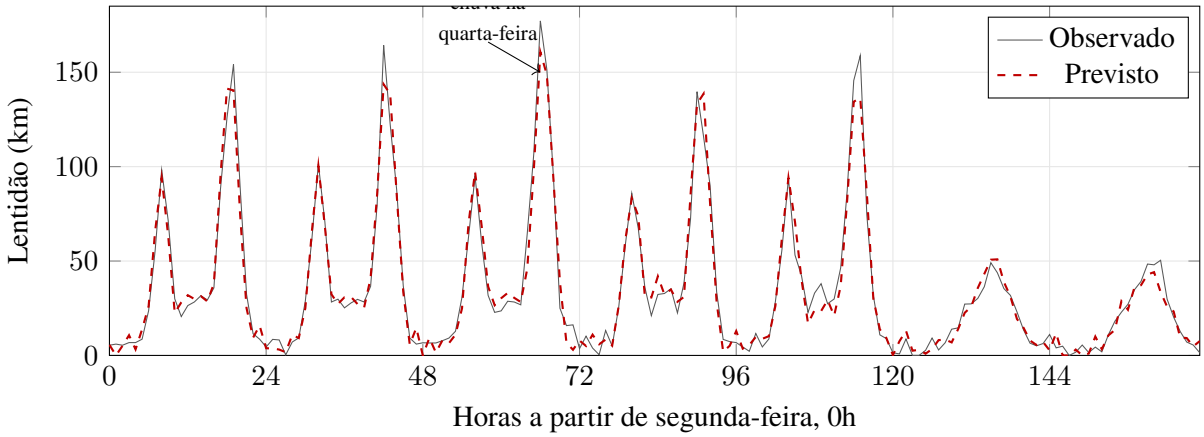
Faixa	Horário	Lentidão média (km)	MAE (km)	MAE relativo (%)
Madrugada	0h a 5h59	6,4	3,0	46,9
Pico manhã	6h a 9h59	64,7	11,2	17,3
Entrepico	10h a 15h59	28,9	7,8	27,0
Pico tarde	16h a 20h59	117,0	16,8	14,4
Noite	21h a 23h59	16,0	4,6	28,8

Fonte: Elaborada pela autora (2027).

A Figura 6 compara os valores observados e previstos ao longo de uma semana do conjunto de teste. O modelo reproduz a dinâmica dos picos, inclusive o aumento atípico da quarta-feira, associado a um episódio de chuva no fim da tarde, embora subestime parcialmente sua intensidade.

EXEMPLO DIDÁTICO: trabalho fictício, com dados simulados, elaborado para ilustrar o uso do modelo

Figura 6 – Lentidão observada e prevista pelo XGBoost em uma semana do conjunto de teste



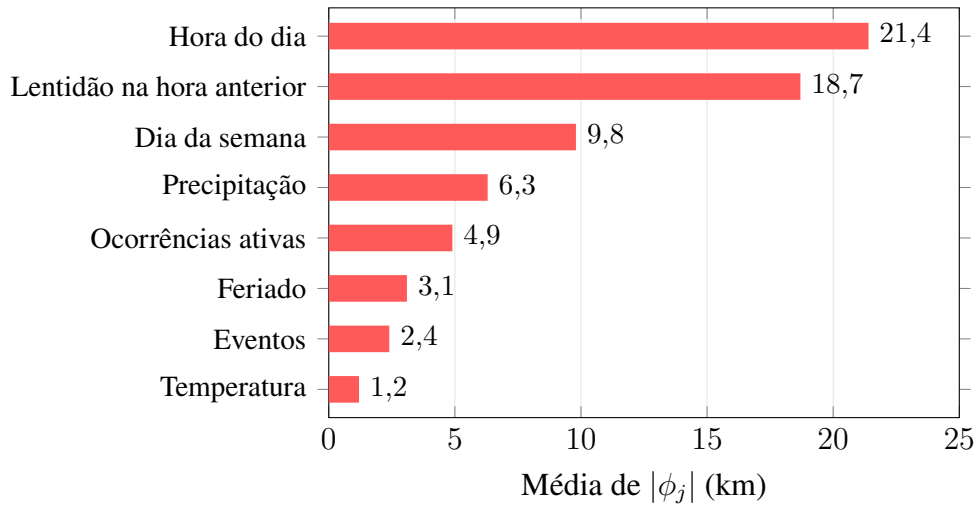
Fonte: Elaborada pela autora (2027).

4.3 Explicação das previsões

4.3.1 Explicação global

A importância global de cada variável, medida pela média dos valores SHAP absolutos no conjunto de teste, é apresentada na Figura 7. A hora do dia e a lentidão observada na hora anterior respondem, em conjunto, por mais da metade da contribuição total, o que confirma o caráter fortemente sazonal e persistente da série. Entre os fatores contextuais, a precipitação e as ocorrências ativas superam o feriado e os eventos de grande porte.

Figura 7 – Importância global das variáveis: média dos valores SHAP absolutos

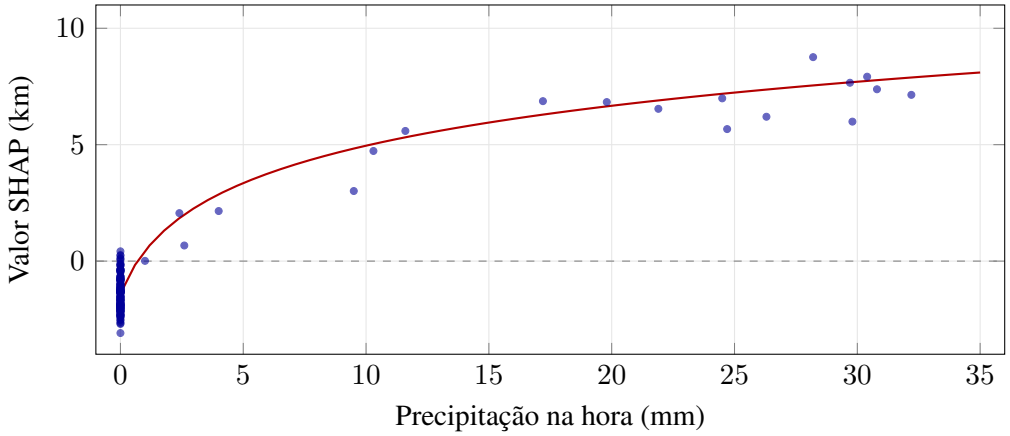


Fonte: Elaborada pela autora (2027).

A relação entre a precipitação e sua contribuição para a previsão é detalhada na Figura 8. Chuvas fracas, de até 2 mm, têm efeito praticamente nulo, enquanto precipitações acima de

10 mm elevam a previsão em 5 a 9 km. O crescimento é côncavo: o efeito marginal de cada milímetro adicional diminui com a intensidade, o que sugere um limite de saturação da rede viária.

Figura 8 – Dependência entre a precipitação e o respectivo valor SHAP



Fonte: Elaborada pela autora (2027).

4.3.2 Explicação local

Para ilustrar a explicação de uma previsão individual, o Quadro 2 decompõe a previsão de 146 km para as 18h de uma quarta-feira com chuva prevista de 12 mm. Conforme a Equação (2.5), a previsão corresponde ao valor de base somado às contribuições de cada variável.

Quadro 2 – Decomposição da previsão para as 18h de uma quarta-feira chuvosa

Componente	**Valor observado**	**Contribuição (km)**	**Interpretação**
Valor de base (ϕ_0)	–	65	Média das previsões
Hora do dia	18h	+38	Pico vespertino
Lentidão na hora anterior	112 km	+24	Congestionamento já instalado
Precipitação	12 mm	+9	Chuva moderada
Dia da semana	quarta	+7	Dia útil
Ocorrências ativas	6	+5	Acima da média
Temperatura	19 °C	−2	Efeito marginal
Previsão	–	**146**	Soma das parcelas

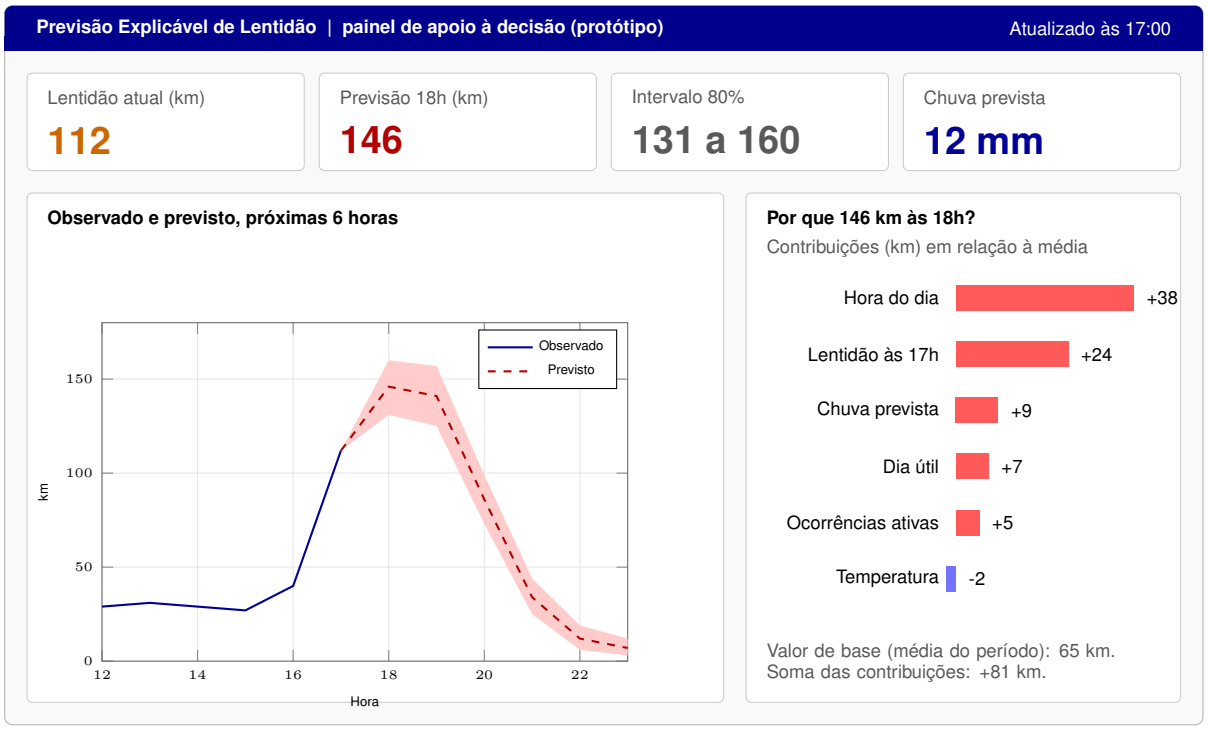
Fonte: Elaborado pela autora (2027).

4.4 Protótipo de painel de apoio à decisão

As previsões e explicações foram incorporadas a um protótipo de painel, ilustrado na Figura 9. A interface apresenta a lentidão atual, a previsão para a próxima hora com intervalo

de 80%, a trajetória prevista para as horas seguintes e, à direita, a decomposição da previsão selecionada. Essa última área materializa a proposta central da pesquisa: o gestor não recebe apenas um número, mas a indicação de quais fatores o produzem e com que intensidade.

Figura 9 – Protótipo do painel de previsão explicável



Fonte: Elaborada pela autora (2027).

4.5 Discussão

Os resultados confirmam, para o contexto de São Paulo, a superioridade dos modelos baseados em árvores sobre os modelos sazonais clássicos, em linha com a evolução descrita por Vlahogianni; Karlaftis; Golias (2014). O ganho do XGBoost sobre o *Gradient Boosting* tradicional, embora menor que o observado entre as famílias de modelos, é coerente com o efeito da regularização descrito por Chen; Guestrin (2016). Ao contrário do aprendizado profundo explorado por Lv *et al.* (2015), os modelos aqui adotados alcançaram bom desempenho com uma base de porte moderado e mantiveram a possibilidade de explicação exata por meio do TreeSHAP.

A análise explicativa acrescenta uma dimensão ausente na maioria dos estudos analisados. A predominância da hora do dia e da defasagem era esperada, mas a forma não linear do efeito da chuva tem implicação operacional direta: a partir de cerca de 10 mm, a resposta da rede satura, de modo que medidas preventivas devem ser acionadas já na previsão de chuva moderada, e não apenas diante de eventos extremos. Esse tipo de leitura, viabilizado pela propriedade aditiva da Equação (2.5), aproxima o modelo da linguagem do gestor e responde à preocupação

com a confiança em modelos complexos discutida por Arrieta *et al.* (2020).

EXEMPLO DIDÁTICO: trabalho fictício, com dados simulados, elaborado para ilustrar o uso do modelo

5 CONCLUSÃO

Esta dissertação teve como objetivo desenvolver e avaliar um sistema inteligente de previsão explicável da extensão de lentidão viária em São Paulo, com horizonte de uma hora, voltado ao apoio à decisão. Este capítulo retoma a pergunta de pesquisa, sintetiza as contribuições e apresenta as limitações e os desdobramentos possíveis.

5.1 Resposta à pergunta de pesquisa

A Pergunta de Pesquisa indagava em que medida um sistema baseado em aprendizado de máquina e valores de Shapley seria capaz de prever com acurácia a lentidão e de explicar de forma inteligível os fatores de cada previsão. Os resultados permitem responder afirmativamente aos dois componentes da pergunta, com as ressalvas indicadas na Seção 5.3.

Quanto à acurácia, o XGBoost alcançou erro absoluto médio de 7,6 km e coeficiente de determinação de 0,88 no conjunto de teste, o que representa redução de 48,6% em relação à média histórica (Tabela 2). Quanto à explicabilidade, a decomposição aditiva das previsões permitiu identificar a contribuição de cada fator e traduzi-la em uma interface compreensível (Figura 9).

Os objetivos específicos foram atendidos da seguinte forma: (1) a revisão sistemática mapeou 23 estudos e evidenciou a lacuna na integração entre previsão e explicação; (2) a base horária integrou quatro fontes ao longo de três anos; (3) a comparação de cinco modelos sob validação temporal identificou o XGBoost como o de melhor desempenho; e (4) as explicações SHAP foram incorporadas ao protótipo de painel.

5.2 Contribuições teóricas e práticas

No plano teórico, o trabalho demonstra que a explicabilidade pode ser tratada como componente do artefato de apoio à decisão, e não apenas como análise posterior ao modelo. A identificação do efeito não linear da precipitação, com saturação a partir de cerca de 10 mm, é um exemplo de conhecimento que emerge da explicação e não seria evidente a partir das métricas de erro. No plano prático, o protocolo de validação e o protótipo de painel oferecem uma referência reproduzível para órgãos de gestão do tráfego interessados em adotar modelos preditivos com transparência.

5.3 Limitações

Das limitações previstas na Seção 3.8, confirmaram-se a ausência de dados de obras e interdições, que explica parte dos maiores erros residuais, e a resolução horária da precipitação, que contribuiu para a subestimação de episódios de chuva intensa e curta (Figura 6). Além disso, o painel foi avaliado apenas como protótipo, sem teste com gestores em ambiente operacional,

EXEMPLO DIDÁTICO: trabalho fictício, com dados simulados, elaborado para ilustrar o uso do modelo

de modo que sua utilidade percebida ainda não foi mensurada.

5.4 Trabalhos futuros

Como desdobramentos, sugerem-se: (i) a incorporação de dados de obras programadas e de precipitação em resolução de 15 minutos; (ii) a extensão da previsão para o nível de trecho viário, com modelos que capturem a dependência espacial entre corredores; e (iii) a avaliação do painel com gestores de tráfego, por meio de estudo de usabilidade e de confiança nas explicações.

EXEMPLO DIDÁTICO: trabalho fictício, com dados simulados, elaborado para ilustrar o uso do modelo

DECLARAÇÃO DE USO DE IA GENERATIVA

Esta declaração documenta o uso de ferramentas de inteligência artificial generativa na elaboração desta dissertação. Para cada intervenção, reportam-se a *localização* (em que seções a ferramenta atuou), a *extensão* (a natureza da operação realizada) e a *verificação* (o procedimento pelo qual a autora examinou o resultado antes de incorporá-lo).

Ferramentas utilizadas

- **Modelo de linguagem de grande porte** (nome e versão registrados no repositório do projeto), acessado por interface de chat em plano institucional, com mecanismo de busca na web desativado e uso dos dados para treinamento desabilitado, em sessões conduzidas entre agosto de 2026 e fevereiro de 2027.

Intervenções e sua incidência sobre as afirmações

As intervenções restringiram-se ao suporte linguístico e à revisão de código, sem incidir sobre as afirmações substantivas que fundamentam as conclusões do trabalho:

1. **Sugestões de concisão e clareza textual**. *Localização:* Capítulos 1 e 5. *Extensão:* reformulação sintática de frases preexistentes. *Verificação:* as sugestões foram aceitas apenas quando preservaram o sentido e o alcance das afirmações originais.

2. **Revisão de código**. *Localização:* rotinas de pré-processamento descritas na Seção 3.5. *Extensão:* identificação de erros de sintaxe e sugestões de legibilidade. *Verificação:* todas as alterações foram testadas pela autora, e os resultados foram conferidos com a versão anterior do código.

Delimitação da autoria e produção não mediada por IA

A formulação do problema e da pergunta de pesquisa, o desenho metodológico, a seleção dos estudos da revisão sistemática, a construção da base de dados, a modelagem, a análise dos resultados e todas as tabelas, quadros e figuras foram elaborados pela autora, sem uso de ferramentas de IA generativa. Nenhuma referência foi sugerida ou gerada por essas ferramentas.

EXEMPLO DIDÁTICO: trabalho fictício, com dados simulados, elaborado para ilustrar o uso do modelo

REFERÊNCIAS

ARRIETA, A. B. *et al.* Explainable artificial intelligence (XAI): concepts, taxonomies, opportunities and challenges toward responsible AI. **Information Fusion**, v. 58, p. 82–115, 2020. DOI: https://doi.org/10.1016/j.inffus.2019.12.012.

BERGMEIR, C.; BENíTEZ, J. M. On the use of cross-validation for time series predictor evaluation. **Information Sciences**, v. 191, p. 192–213, 2012. DOI: https://doi.org/10.1016/j.ins.2011.12.028.

BOX, G. E. P.; DRAPER, N. R. **Empirical model-building and response surfaces**. New York: Wiley, 1987.

BREIMAN, L. Random forests. **Machine Learning**, v. 45, n. 1, p. 5–32, 2001. DOI: https://doi.org/10.1023/A:1010933404324.

CHEN, T.; GUESTRIN, C. XGBoost: a scalable tree boosting system. In: **Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining**. San Francisco: ACM, 2016. p. 785–794. DOI: https://doi.org/10.1145/2939672.2939785.

FRIEDMAN, J. H. Greedy function approximation: a gradient boosting machine. **The Annals of Statistics**, v. 29, n. 5, p. 1189–1232, 2001. DOI: https://doi.org/10.1214/aos/1013203451.

HEVNER, A. R. *et al.* Design science in information systems research. **MIS Quarterly**, v. 28, n. 1, p. 75–105, 2004. DOI: https://doi.org/10.2307/25148625.

HYNDMAN, R. J.; ATHANASOPOULOS, G. **Forecasting: principles and practice**. 3. ed. Melbourne: OTexts, 2021. Disponível em: https://otexts.com/fpp3/. Acesso em: 10 mar. 2026.

KITCHENHAM, B.; CHARTERS, S. **Guidelines for performing systematic literature reviews in software engineering**. Keele, 2007.

LUNDBERG, S. M. *et al.* From local explanations to global understanding with explainable AI for trees. **Nature Machine Intelligence**, v. 2, n. 1, p. 56–67, 2020. DOI: https://doi.org/10.1038/s42256-019-0138-9.

LUNDBERG, S. M.; LEE, S.-I. A unified approach to interpreting model predictions. In: **Advances in Neural Information Processing Systems 30**. Long Beach: Curran Associates, 2017. p. 4765–4774.

LV, Y. *et al.* Traffic flow prediction with big data: a deep learning approach. **IEEE Transactions on Intelligent Transportation Systems**, v. 16, n. 2, p. 865–873, 2015. DOI: https://doi.org/10.1109/TITS.2014.2345663.

MOLNAR, C. **Interpretable machine learning: a guide for making black box models explainable**. 2. ed. Munique: Christoph Molnar, 2022. Disponível em: https://christophm.github.io/interpretable-ml-book/. Acesso em: 10 mar. 2026.

PAGE, M. J. *et al.* The PRISMA 2020 statement: an updated guideline for reporting systematic reviews. **BMJ**, v. 372, p. n71, 2021. DOI: https://doi.org/10.1136/bmj.n71.

PEDREGOSA, F. *et al.* Scikit-learn: machine learning in Python. **Journal of Machine Learning Research**, v. 12, p. 2825–2830, 2011.

RIBEIRO, M. T.; SINGH, S.; GUESTRIN, C. "why should I trust you?": explaining the predictions of any classifier. In: **Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining**. San Francisco: ACM, 2016. p. 1135–1144. DOI: https://doi.org/10.1145/2939672.2939778.

RUSSELL, S.; NORVIG, P. **Artificial intelligence: a modern approach**. 4. ed. Hoboken: Pearson, 2021.

SHAPLEY, L. S. A value for n-person games. In: KUHN, H. W.; TUCKER, A. W. (Ed.). **Contributions to the theory of games: volume II**. Princeton: Princeton University Press, 1953, (Annals of Mathematics Studies, 28). p. 307–317.

VLAHOGIANNI, E. I.; KARLAFTIS, M. G.; GOLIAS, J. C. Short-term traffic forecasting: where we are and where we're going. **Transportation Research Part C: Emerging Technologies**, v. 43, p. 3–19, 2014. DOI: https://doi.org/10.1016/j.trc.2014.01.005.

WILLIAMS, B. M.; HOEL, L. A. Modeling and forecasting vehicular traffic flow as a seasonal ARIMA process: theoretical basis and empirical results. **Journal of Transportation Engineering**, v. 129, n. 6, p. 664–672, 2003. DOI: https://doi.org/10.1061/(ASCE)0733-947X(2003)129:6(664).

ZHANG, J. *et al.* Data-driven intelligent transportation systems: a survey. **IEEE Transactions on Intelligent Transportation Systems**, v. 12, n. 4, p. 1624–1639, 2011. DOI: https://doi.org/10.1109/TITS.2011.2158001.

APÊNDICE A – Expressões de busca da revisão sistemática

Scopus

Quadro 3 – Expressão de busca aplicada na base Scopus

```
TITLE-ABS-KEY(
  ("traffic congestion" OR "traffic flow" OR "traffic speed")
  AND (forecast* OR predict*)
  AND ("machine learning" OR "gradient boosting" OR
       "random forest" OR "XGBoost" OR "deep learning")
  AND (explainab* OR interpretab* OR "SHAP")
)
AND PUBYEAR > 2014 AND PUBYEAR < 2026
AND LANGUAGE(English) AND DOCTYPE(ar)
```

Data da busca: 12/05/2025. Registros recuperados: 412.

Fonte: Elaborado pela autora (2027).

Web of Science

Quadro 4 – Expressão de busca aplicada na base Web of Science

```
TS=(
  ("traffic congestion" OR "traffic flow" OR "traffic speed")
  AND (forecast* OR predict*)
  AND ("machine learning" OR "gradient boosting" OR
       "random forest" OR "XGBoost" OR "deep learning")
  AND (explainab* OR interpretab* OR "SHAP")
)
```

Filtros: período (2015–2025), tipo (artigo), idioma (inglês). Data da busca: 12/05/2025. Registros recuperados: 287.

Fonte: Elaborado pela autora (2027).

APÊNDICE B – Dicionário de variáveis

O Quadro 5 descreve as variáveis da base de dados utilizada na modelagem.

Quadro 5 – Dicionário de variáveis da base horária

Variável	Tipo	Unidade	Descrição
`lentidao_km`	contínua	km	Extensão total de lentidão (alvo)
`lentidao_lag1`	contínua	km	Lentidão observada na hora anterior
`hora`	discreta	0 a 23	Hora do dia
`dia_semana`	categórica	1 a 7	Dia da semana
`feriado`	binária	0 ou 1	Indicador de feriado
`precipitacao`	contínua	mm	Precipitação acumulada na hora
`temperatura`	contínua	°C	Temperatura média do ar
`ocorrencias`	discreta	contagem	Ocorrências viárias ativas
`eventos`	binária	0 ou 1	Evento de grande porte na cidade

Fonte: Elaborado pela autora (2027).

APÊNDICE C – Trecho do código de modelagem

O código completo está disponível no repositório do projeto. O trecho a seguir apresenta o treinamento do modelo final e o cálculo dos valores SHAP.

```python
import pandas as pd
import shap
from xgboost import XGBRegressor

df = pd.read_parquet("dados/base_horaria.parquet")
treino = df[df["data_hora"] < "2024-01-01"]
teste = df[df["data_hora"] >= "2024-01-01"]

variaveis = ["hora", "dia_semana", "feriado", "lentidao_lag1",
             "precipitacao", "temperatura", "ocorrencias", "eventos"]

modelo = XGBRegressor(n_estimators=600, learning_rate=0.05,
                      max_depth=6, subsample=0.8, random_state=42)
modelo.fit(treino[variaveis], treino["lentidao_km"])

explicador = shap.TreeExplainer(modelo)
valores_shap = explicador.shap_values(teste[variaveis])
```

ANEXO A – Termo de autorização de uso de dados

TERMO DE AUTORIZAÇÃO DE USO DE DADOS
(documento fictício, reproduzido apenas para ilustrar a inclusão de anexos)

A Instituição Parceira Exemplo autoriza a pesquisadora Marina Exemplo de Oliveira, mestranda do Programa de Pós-Graduação em Informática e Gestão do Conhecimento da Universidade Nove de Julho, a utilizar os dados agregados de monitoramento de tráfego referentes ao período de 2022 a 2024, exclusivamente para fins acadêmicos.
São condições desta autorização: (i) a não identificação de pessoas ou veículos; (ii) a citação da fonte em publicações; e (iii) a vedação de uso comercial dos dados.

Responsável pela Instituição Parceira Exemplo
São Paulo, 10 de abril de 2025